

# UQ-ORION

面向恶劣天气的不确定性感知端到端自动驾驶安全扩展

---

2026 年 4 月 1 日

1. 背景与动机
2. 总体框架
3. UQEstimator
4. FiLM 调制
5. 训练流程与结果
6. 实验结果：回答研究问题
7. 诊断与下一步

## 背景与动机

---

# ORION: VLM-based 端到端自动驾驶


**ORION** (ICCV 2025) 流程:

1. 多视角图像 → EVAViT encoder
2. QT-Former 场景理解
3. Qwen VLM 推理 + 规划
4. VAE 解码 → 轨迹

**优势:** 利用 VLM 的世界知识做驾驶决策

**问题:** 在恶劣天气下**过度自信**

- 不知道“自己看不清了”
- 依然做出激进决策



## 核心发现：恶劣天气碰撞率放大 161×

| 指标     | Normal | Adverse | 倍数    |
|--------|--------|---------|-------|
| L2@3s  | 2.38m  | 1.78m   | 0.75× |
| Col@1s | 0.02%  | 1.78%   | 89×   |
| Col@3s | 0.01%  | 1.61%   | 161×  |

### 反直觉发现

- 恶劣天气的 L2 误差反而更低（低速 → 短轨迹 → 天然低 L2）
- 但碰撞率高出 161 倍
- L2 轨迹精度 ≠ 安全性，开环指标看不出问题

数据来源：Bench2Drive 验证集，12,806 个样本（开环评估）

Adverse 判定：Weather ID  $\notin \{0, 1, 2, 3\}$ ，即非 ClearNoon/ClearSunset/CloudyNoon/CloudySunset 的所有条件

# 阶段性研究问题

本阶段不刷榜 L2，在冻结 ORION 主干上回答四个问题：

**Q1 能否监测？**

从冻结视觉 patch tokens 估计「当前感知有多差」(UQ score)

**Q2 能否改行为？**

不修改主干权重，用 FiLM 条件调制规划 (QT-Former + VAE)

**Q3 代价是什么？**

碰撞率改善是否以 Normal 轨迹退化、效率下降为代价？

**Q4 能否空间化？**


不确定性能否从全局标量扩展到 BEV 空间热力图？

评估：开环 12,806 帧 + 50 场景回放式闭环；Adverse = Weather ID  $\notin \{0, 1, 2, 3\}$ 。

# 总体框架

---

## 整体架构：轻量 UQ + 双层 FiLM 注入



### 设计原则：

- 零主干微调
- 新增参数 4.45M（主干的 0.45%）
- 一行开关切换

**FiLM 调制：**  $\text{out} = \gamma \odot \text{in} + \beta$

- L1：调制场景理解
- L2：调制轨迹规划
- Identity 初始化保证无损

# UQEstimator

---

# UQEstimator: 模块定位

## 做什么？

- 读取 ORION **frozen** EVAViT 的 patch tokens
- 输出 **uncertainty\_score**  $\in (0, 1)$  (标量)
- 输出 **uncertainty\_embedding**  $\in \mathbb{R}^{256}$  (供 FiLM)


## 不做什么？

- 不微调 Vision / QT-Former / VLM / VAE
- 不直接预测轨迹 L2 或碰撞
- 与 BEV 不确定性模块独立 (见 Phase 2)

| 项            | 值                      |
|--------------|------------------------|
| 参数量          | <b>2.21M</b>           |
| 上限目标         | $< 5M$                 |
| 训练显存         | $< 5GB$                |
| 训练时长         | $\sim 100 \text{ min}$ |
| Val Spearman | <b>0.97</b>            |

推理时通过 forward hook 捕获 score，  
不改动 ORION 主推理图。

# UQEstimator: 端到端数据流



## Patch 分支 (1/2): Cross-Attention 聚合

为何需要 Decoder?

- 单帧  $6 \times 1600$  patches, 直接 mean pool 会丢失空间结构
- 16 个可学习 query 对全图 patch 做 cross-attention
- 2 层 TransformerDecoderLayer ( $d=256$ , 8 heads)
- 再对 6 视角的 query 输出做 mean  $\rightarrow [B, 256]$

数据流 (每视角)

patch tokens  $\xrightarrow{\text{Linear}}$  patch 序列  $\xrightarrow{\text{Decoder}}$  16 queries  $\xrightarrow{\text{mean}}$  256-d  $\xrightarrow{\text{6-view mean}}$   $[B, 256]$

消融: `use_transformer_decoder=false`

- 退化为 patch 维 mean pool (更快、表达能力更弱)

## Patch 分支 (2/2): 张量约定与训练

### 输入张量约定

| 符号           | 形状                   |
|--------------|----------------------|
| patch_tokens | $[B, 6, 1600, 1024]$ |
| 投影后          | $[B, 6, 1600, 256]$  |
| queries      | $[B, 6, 16, 256]$    |
| 视角聚合后        | $[B, 256]$           |

EVAViT 输出  $D=1024$ ; UQEstimator 内先投影到  $d=256$  再进 Decoder。

### 训练与工程

- `n_patches_subsample=256`: 每视角随机子采样 patch, 加速训练
- Stage 0 特征缓存: 12,806 帧  $\rightarrow$  `data/features/*.pt`
- 推理全量 1600 patch / 视角 (与训练子采样可不同)

### 参数量

- Patch 投影 +  $2 \times$  Decoder 占 UQEstimator 主体
- 总模型约 **2.24M** (上限 5M)

## 统计特征分支 (1/2): 5 维描述子

来源: `compute_stat_features(tokens)` (`dataset.py`)


从 Stage 0 缓存的 patch tokens 离线计算, 不增加 **ORION** 主推理计算图。

| # | 特征                | 设计直觉                                   |
|---|-------------------|----------------------------------------|
| 0 | patch 激活方差均值      | 表征是否“发散”、不稳定                           |
| 1 | 跨 patch softmax 熵 | 归一化到 $[0, 1]$ ; 熵高 $\Rightarrow$ 注意力分散 |
| 2 | 跨视角 token 余弦相似度   | 多相机表征是否一致                              |
| 3 | 激活绝对值均值           | 整体信号强度                                 |
| 4 | 激活最大值均值           | 是否存在异常强响应 patch                        |

5 维原始特征  $\rightarrow$  模型内  $\text{Linear}(5 \rightarrow 64) + \text{GELU} + \text{LayerNorm}$ , 再与 Patch 分支  $[B, 256]$  concat。

## 统计特征分支 (2/2): 结构与消融

### 分支结构



与 Patch 分支在 Fusion MLP 前拼接:

$$256 + 64 = 320.$$

### 工程与消融

- 消融: `use_stat_features=false` 时整路跳过, Fusion 输入仅  $[B, 256]$
- 缓存: 可选 `stat_cache.pt`, 避免每个 epoch 重算 5 维特征
- 互补: Patch 路做空间聚合; 统计路无 attention、可解释, 显式编码分布形态

设计取舍: 去掉统计分支 (`no_stat`) 时劣天气分离度与 Spearman 通常下降; 保留成本极低 ( $5 \rightarrow 64$  投影 + 固定公式, 不增加 ORION 推理开销)。

# 损失函数 (1/4): 监督对象与总目标

## 训练监督谁?

- 仅对 **score\_head** 输出  $\hat{s} \in [0, 1]$  (Sigmoid) 计算损失; **embed\_head** 无直接监督
- 标签  $t$  为 Stage 1a 伪标签 (patch 统计 + weather 校准), 形状  $[B, 1]$
- 实现: `uq_estimator/losses.py`  $\rightarrow$  `CombinedUQLoss`

## 总损失 (默认权重)

$$\mathcal{L}_{\text{total}} = \underbrace{\text{MSE}(\hat{s}, t)}_{\mathcal{L}_{\text{reg}}} + \underbrace{\lambda_{\text{cal}} \cdot \frac{1}{\text{std}(\hat{s}) + \epsilon}}_{\mathcal{L}_{\text{cal}}, \lambda_{\text{cal}}=0.1} + \underbrace{\lambda_{\text{rank}} \cdot \mathcal{L}_{\text{rank}}}_{\lambda_{\text{rank}}=0.5}$$

`forward` 返回字典: `total, regression, ranking, calibration` (便于 TensorBoard / 日志分项监控)。

## 损失函数 (2/4): 回归项 $\mathcal{L}_{\text{reg}}$

### 定义

$$\mathcal{L}_{\text{reg}} = \frac{1}{B} \sum_{i=1}^B (\hat{s}_i - t_i)^2$$

### 作用

- 拟合伪标签绝对数值: 劣天气帧应更接近  $t \approx 1$ , 正常帧更接近 0
- 提供主监督信号, 决定 score 的标定尺度

### 局限 (单独 MSE 不够)

- 对 batch 内相对排序约束弱: 多个样本可共同塌缩到 batch 均值附近仍得较低 MSE
- 故需排序项 + 校准项配合 (见后两页)

### 伪标签 $t$ 从何而来?

- generate\_labels.py: 由 patch token 统计量组合
- v3: 叠加 weather ID 校准, 与开环 Adverse 划分对齐
- $t \in [0, 1]$ , 连续值而非二分类 0/1

### 与 embed 的关系

回归只塑造 **score**; embedding 通过共享 Fusion 层间接受影响, 但无独立 MSE/对比损失。

## 损失函数 (3/4): 校准项 $\mathcal{L}_{\text{cal}}$ (防塌缩)

定义 (对当前 mini-batch 内预测分数求标准差)

$$\mathcal{L}_{\text{cal}} = \lambda_{\text{cal}} \cdot \frac{1}{\text{std}(\hat{s}) + \epsilon}, \quad \lambda_{\text{cal}} = 0.1, \epsilon = 10^{-6}$$

直觉

- $\text{std}(\hat{s}) \downarrow \Rightarrow \mathcal{L}_{\text{cal}} \uparrow$ : 惩罚“整批预测几乎相同”
- 防止模型退化为常数输出 (例如全预测  $\approx 0.5$ ), 保留 batch 内可分辨率
- 与  $\mathcal{L}_{\text{reg}}$  互补: MSE 管“对准标签”, 校准管“别把方差压没”

实现细节

- `pred_score.std()`: PyTorch 默认无偏估计 ( $n-1$  分母)
- $B=1$  时 **std** 为 **NaN**: 训练配置 `batch_size=64`, 勿长期用  $B=1$  调试

消融

- `configs/uq_ablation_no_cal.yaml`:  
`use_calibration: false`  $\Rightarrow \lambda_{\text{cal}}=0$
- 关闭后 score 分布可能变窄, Normal/Adverse 分离度下降

## 损失函数 (4/4): 排序项与组合

### 成对排序 $\mathcal{L}_{\text{rank}}$

- 枚举 batch 内所有满足  $t_i > t_j$  的样本对  $(i, j)$
- 用 `nn.MarginRankingLoss(margin=0.1)`, 约束

$$\hat{s}_i \geq \hat{s}_j + 0.1$$

- 若无有效对 (如标签全相等)  $\Rightarrow$  返回 0 (`requires_grad=True`)
- 复杂度: 每 batch 最多  $O(B^2)$  对;  $B=64$  时约  $\leq 2016$  对

小例子 ( $B=3$ ): 若  $t = [0.2, 0.5, 0.9]$ , 有效对为  $(2, 0), (2, 1), (1, 0)$  共 3 对; 要求  $\hat{s}_2 > \hat{s}_0$ ,  $\hat{s}_2 > \hat{s}_1$ ,  $\hat{s}_1 > \hat{s}_0$  (均带 margin)。

### YAML 消融 (train\_uq.py 置 $\lambda=0$ )


| 配置         | 关闭项                         |
|------------|-----------------------------|
| no_ranking | $\mathcal{L}_{\text{rank}}$ |
| no_cal     | $\mathcal{L}_{\text{cal}}$  |
| no_stat    | 统计分支                        |
| no_decoder | Transformer Decoder         |

### 三项分工

- $\mathcal{L}_{\text{reg}}$ : 绝对值回归
- $\mathcal{L}_{\text{cal}}$ : batch 内分散度
- $\mathcal{L}_{\text{rank}}$ : 相对序关系 (劣天气  $>$  正常)

## score vs embedding (1/2): Stage 1b 谁有监督?

网络分叉 (uq\_estimator/model.py)



| 模块                    | 梯度 | 说明            |
|-----------------------|----|---------------|
| Patch / Stat / Fusion | ✓  | 经 score 路径反传  |
| score_head            | ✓  | MSE + 校准 + 排序 |
| embed_head            | ×  | 与 loss 并行, 旁路 |

结论: 可解释、可验证的是 **score** (AUROC、Normal/Adverse 分离); Fusion 表征为 score 服务。

## score vs embedding (2/2): 下游语义与改进

### ORION / FiLM 怎么用?

- `orion_head` 输出 `uq_out.embedding`  
→ FiLM L1/L2 调制
- `uq_out.score` → Score-Gated FiLM  
( $\gamma, \beta$  按 score 缩放)
- `train_film.py`: 通常冻结 UQ, 只训 FiLM 层

### embedding 的实际地位

- 携带 Fusion 信息, 但未针对规划/FiLM 优化
- 不是“完全无用”, 也不等于 score 同等可靠

### 两路输出对比

| 输出        | 语义               |
|-----------|------------------|
| score     | 帧级不确定性分数, 有伪标签监督 |
| embedding | 调制向量; UQ 阶段无独立监督 |

### 可选改进

- FiLM 阶段解冻 UQ (至少 `embed_head`)
- 对 embedding 加 L2 / 碰撞辅助损失
- FiLM 直接用 Fusion 输出, 去掉未训练头
- Stage 1b + 2b 端到端联合训练

## FILM 调制

---

## FiLM: 双层注入与实现

注入位置 (ORION 冻结, 只训  $\gamma, \beta$ ):

- **FiLM L1** (0.13M): QT-Former query, 调制场景理解
- **FiLM L2** (2.11M): VAE current\_states, 调制轨迹解码
- 条件向量: `uq_out.embedding [B, 256]`
- 门控标量: `uq_out.score [B, 1]` (Score-Gated)

调制公式:  $\text{out} = \gamma \odot \text{in} + \beta$ ; **Identity** 初始化 ( $\gamma \rightarrow 1, \beta \rightarrow 0$ )。

`petr_transformers.py` (L1)、`orion.py` (L2)。

# 双输出头：score 与 embedding 的分工

## score\_head

- Linear( $256 \rightarrow 1$ ) + Sigmoid
- 输出  $[B, 1]$ ，训练时 唯一有 loss 的输出
- 用途：天气/退化监测、FiLM 门控权重

## embed\_head

- Linear( $256 \rightarrow 256$ ) + LayerNorm
- 输出 uncertainty\_embedding
- 注入 QT-Former / VAE 的 FiLM 调制

## Score-Gated FiLM (已实现)

$$\gamma = 1 + s \cdot (\gamma_{\text{raw}} - 1)$$

$$\beta = s \cdot \beta_{\text{raw}}$$

$s \rightarrow 0$ : 恒等调制 (晴天几乎透明)

$s \rightarrow 1$ : 全幅度 FiLM

UQOutput.attn\_weights 字段当前为 None;

BEV 方案不依赖 attention 权重。

## 碰撞感知 FiLM 训练

传统 L2 loss 训练的 FiLM 无法降低碰撞率（反而 +4.3%），因此我们设计了碰撞感知训练目标：

$$\mathcal{L}_{\text{FiLM}} = \mathcal{L}_{\text{plan}} + 0.5 \cdot \underbrace{\mathbb{E} [\text{ReLU}(m - d_{\min}) \cdot s_{\text{UQ}}]}_{\text{UQ-weighted collision margin loss}}$$

关键设计：

- Margin  $m = 4.0\text{m}$  ( $\approx 2$  车身宽度)
- UQ score 作为权重 (detached)  
高不确定性  $\rightarrow$  更强碰撞惩罚
- 冻结 ORION 主干，只训 FiLM


Margin 选择实验：

| Margin      | 有效帧                           | 说明    |
|-------------|-------------------------------|-------|
| 2.0m        | $\sim 0\%$                    | 无梯度信号 |
| <b>4.0m</b> | <b><math>\sim 30\%</math></b> | 合理    |
| 5.0m        | $\sim 60\%$                   | 过于激进  |

## 训练流程与结果

---

## 训练流水线：特征 → 伪标签 → 训练



### 默认训练 (uq\_train.yaml)

- 20 epochs, batch 64, lr  $3 \times 10^{-4}$
- warmup 3 + cosine
- val\_ratio 10%
- **Epoch 2** 达 Spearman 0.97

### 产出

- checkpoints/uq/best.pt
- reports/uq\_validation/ 图表
- 接入 eval\_openloop.py hook

## 伪标签迭代 (1/2): $v1 \rightarrow v2 \rightarrow v3$

| 版本 | 要点                                         | AUROC              | 状态  |
|----|--------------------------------------------|--------------------|-----|
| v1 | gradient 恒权 + 弱 entropy; min-max 校准        | 0.621              | 已废弃 |
| v2 | max_mean 50% + cosim 35% + entropy 15%     | 0.993 <sup>†</sup> | 备份  |
| v3 | <b>weather-based</b> scene_type, 与 eval 一致 | <b>0.954</b>       | 当前  |


### v3 的关键修正

- 统一 Normal/Adverse 定义: 与 eval\_openloop weather 划分对齐
- 百分位校准替代 min-max: 避免极端值压缩间隔
- 保留可解释特征权重 (max\_mean / cosim / entropy)


<sup>†</sup> v2 的 0.993 在自身标签空间内; 对齐 weather 后仅 ~0.60。

**19.4%** 样本 (2,481/12,806) 在 v2 与 eval 的 Normal/Adverse 定义不一致。

## 伪标签迭代 (2/2): 拟合与分布



预测 vs 伪标签 (Val Spearman 0.95)



按标签分组的 score 分布

## 实验结果：回答研究问题

---

## Q1: UQ 能否监测感知退化?

问题：在冻结 ORION 上，侧信道能否判断「当前视觉条件有多差」?

### 监测器（本阶段验证）

- 输出：uncertainty\_score  $\hat{s} \in (0, 1)$
- 标签：Weather ID 0-3 = Normal，其余 = Adverse
- 数据：B2D val **12,806** 帧（50 clips）
- 模型：v3 best.pt + eval\_openloop

### 结论（ch03）

- **AUROC = 0.954** ( $> 0.7$  门槛)
- **Gap = 0.87** (Adverse—Normal 均值)
- UQ 回答「看得有多差」，非「规划会偏多少」

详见 0521report/ch03-UQ 结果.md；数字源 results/eval\_openloop\_v3.json。

## 开环验证：UQ 能否区分 Normal / Adverse?


|              | Normal       | Adverse               | 说明                  |
|--------------|--------------|-----------------------|---------------------|
| 样本数（帧）       | 2,709        | 10,097                | <b>50 val clips</b> |
| UQ 均值        | 0.023        | 0.893                 | 几乎不重叠               |
| UQ 中位数       | 0.00008      | 0.970                 | 双峰分布                |
| <b>Gap</b>   | <b>0.870</b> | <b>adverse-normal</b> |                     |
| <b>AUROC</b> | <b>0.954</b> | <b>weather 二分类</b>    |                     |

### 与训练指标的区别


- Val Spearman 0.97：拟合伪标签
- AUROC 0.954：区分天气（独立验证）


代表性天气 UQ ClearNoon 0.0001 |  
CloudyNoon 0.072  
MidRainyNoon 0.231 | HardRainNight 0.989  
MidRainSunset 0.997

## UQ Score 分布 (Normal vs Adverse)



## ROC: UQ 作为 Adverse 检测器





## 监测 $\neq$ 规划误差预测器

### 分组均值 (Baseline 规划, 同 12,806 帧)

|        | Normal | Adverse |
|--------|--------|---------|
| L2@3s  | 2.38 m | 1.78 m  |
| Col@3s | 0.01%  | 1.61%   |

Adverse **L2** 更低但 碰撞  $\approx 161\times$

$\Rightarrow$  不能用 L2 代理安全。

### UQ score 相关性 (v3)

| 相关                   | $\rho / r$ |
|----------------------|------------|
| Spearman(UQ, L2@3s)  | 0.14       |
| Spearman(UQ, Col@3s) | 0.06       |
| Pearson(UQ, L2@3s)   | -0.04      |

弱相关: score 刻画感知退化,  
不能直接预测碰撞  $\Rightarrow$  需碰撞感知 FiLM。


## 伪标签自洽性：为何分数可信？

1. 训练内：Val Spearman  $\approx 0.97$ （拟合伪标签；epoch 2 即平台）
2. 训练外：weather 二分类 AUROC **0.954**，Gap **0.87**（标签未直接优化此目标）
3. 语义上：fig4 降水/雾/夜  $\hat{s}$  单调升高；ClearNoon  $\approx 0$ ，HardRain  $\approx 1$

v2 教训：AUROC 0.993 仅在旧 scene\_type 空间有效；与 eval 对齐后  $\approx 0.60$ 。

19.4% 样本（2,481 帧）标签不一致  $\Rightarrow$  v3 改用 weather-based 重标。

# UQ Score vs 规划质量



## 相关性分析:

| 指标                   | 值             |
|----------------------|---------------|
| Spearman(UQ, L2@3s)  | $\rho = 0.14$ |
| Pearson(UQ, L2@3s)   | $r = -0.04$   |
| Spearman(UQ, Col@3s) | $\rho = 0.06$ |

解读 (v3,

eval\_openloop\_v3.json):

- 散点图有趋势但相关性弱
- UQ 是感知监测器, 非 L2/碰撞回归器
- 改行为需碰撞感知 FiLM (ch04)

## 闭环评估：50 场景 Baseline vs FiLM

| 指标                         | Baseline | FiLM v3 | 变化           |
|----------------------------|----------|---------|--------------|
| <b>ALL (50) Col@3s</b>     | 0.66%    | 0.52%   | <b>-21%</b>  |
| ALL ADE@3s                 | 2.46m    | 4.44m   | <b>+80%</b>  |
| Normal (11) Col@3s         | 0.05%    | 0.11%   | +0.06%       |
| Normal ADE@3s              | 2.78m    | 6.00m   | <b>+116%</b> |
| <b>Adverse (39) Col@3s</b> | 0.83%    | 0.64%   | <b>-23%</b>  |
| Adverse ADE@3s             | 2.37m    | 4.00m   | +69%         |

### 碰撞率改善：

- 恶劣天气碰撞率 -23%
- 高风险场景改善最大

### 已知问题：

- Normal ADE +116%
- 根因：FiLM 未做 score 门控
- Score-Gated 代码完成，待重训

## 闭环评估：Score-Gated FiLM（重训后）

| 指标                         | Baseline | Score-Gated | 变化          |
|----------------------------|----------|-------------|-------------|
| <b>ALL (50) Col@3s</b>     | 0.66%    | 0.52%       | <b>-21%</b> |
| ALL ADE@3s                 | 2.46m    | 2.82m       | <b>+15%</b> |
| Normal (11) Col@3s         | 0.05%    | 0.05%       | $\approx 0$ |
| Normal ADE@3s              | 2.78m    | 3.10m       | <b>+12%</b> |
| <b>Adverse (39) Col@3s</b> | 0.83%    | 0.64%       | <b>-23%</b> |
| Adverse ADE@3s             | 2.37m    | 2.58m       | <b>+9%</b>  |

### 保留（与当前 v3 FiLM 同幅）

- 全量 / 恶劣场景 Col@3s 仍约 **-21%** / **-23%**
- 高 UQ 场景仍获得碰撞感知调制收益

### 修复（相对 v3 FiLM）

- Normal ADE: 6.00m  $\rightarrow$  3.10m (+116%  $\rightarrow$  +12%)
- $s \approx 0$  时  $\gamma \rightarrow 1, \beta \rightarrow 0$ , 消除误调制

## L2 Loss FiLM vs 碰撞感知 FiLM

|                | L2 Loss FiLM  | Collision-Aware FiLM |
|----------------|---------------|----------------------|
| Adverse Col@3s | 1.22% (+4.3%) | 0.64% (-23%)         |
| ADE@3s         | 3.90m (+73%)  | 4.44m (+80%)         |

### Insight: L2 优化 $\neq$ 安全优化

- 纯 L2 loss 训练的 FiLM 让碰撞率上升 4.3%
- L2 降低 = 更好地拟合训练分布，但分布本身不含安全信号
- 必须引入碰撞感知目标才能提升安全性

## 关键问题：Normal 场景 ADE 退化 +116%

现象：Normal 场景 UQ score  $\approx 0$ ，FiLM 不应有调制，但 ADE 从 2.78m  $\rightarrow$  6.00m

根因：embed\_head 的 LayerNorm 使所有样本 embedding  $\|\mathbf{e}\| \approx \sqrt{256}$

$$\gamma = W_\gamma \cdot \underbrace{\text{emb}}_{\|\cdot\| \approx 16} + b_\gamma \implies \text{Normal 和 Adverse 调制幅度相当}$$

修复方案：Score-Gated FiLM

$$\gamma = 1 + \underbrace{s}_{\text{score}} \cdot (\gamma_{\text{raw}} - 1)$$

$$\beta = s \cdot \beta_{\text{raw}}$$

$$s \rightarrow 0 : \gamma \rightarrow 1, \beta \rightarrow 0 \quad (\text{identity})$$

$$s \rightarrow 1 : \gamma \rightarrow \gamma_{\text{raw}}, \beta \rightarrow \beta_{\text{raw}}$$

改动量：3 个文件  $\sim$  12 行代码 + FiLM 重训

# “保守捷径”现象

观察：

- Brake MAE +129%
- Throttle MAE +74%
- 模型学会“更慢、更停、更让”
- 碰撞降低但效率退化

本质：安全 vs 效率的权衡（Pareto tradeoff），而非纯改善

第二轮训练方向：

1. 堵捷径：

- 引入进度/速度保持约束
- 舒适性（acc/jerk）正则

2. 门控：

- Score-Gated FiLM
- 低 UQ → 轨迹质量优先
- 高 UQ → 安全优先

3. 约束幅度：

- $\|\gamma - 1\|$  和  $\|\beta\|$  正则
- 防止过强调制

## Phase –1: 关键假设验证（本地完成）

| Q  | 假设                  | 结论                | 影响            |
|----|---------------------|-------------------|---------------|
| Q1 | attn_weights 可提取    | Flash Attn 阻断     | 临时关闭即可        |
| Q2 | BEV query 30×30 网格  | 600+300 learned   | 双线性 → k-NN    |
| Q3 | poses_cls 为 softmax | sigmoid scores    | 减法 → 乘法门控     |
| Q4 | anchor 空间覆盖         | 充分 (IoU<0.5: 89%) | BEV cost 有区分力 |
| Q5 | 16GB 可部分加载          | 待服务器验证            | —             |

### 确认的有利条件:

- UQ score 高度双峰  
Normal  $\approx 0$ , Adverse  $\approx 0.97$
- Score-Gated FiLM 安全可行
- 20 mode 空间展幅 25.7m × 51.9m

### 修正的错误假设:

- BEV query 非规则网格  
→ k-NN 空间插值 (k=5)
- poses\_cls 非 softmax  
→ 乘法门控替代 logit 减法
- Score-Gated 涉及 3 文件  
(非 2 文件, ~12 行非 6 行)

# 现有 FiLM 的空间盲目性

当前信息流失过程：


1.  $\text{patch\_tokens} [B, 6, 1600, 1024]$
2.  $\text{cross-attention} \rightarrow \text{attn\_weights}$  （空间信息在此丢失）
3. **mean pool**  $\rightarrow \text{emb} [B, 256]$
4. FiLM 对所有 BEV query 施加相同调制

结果：无法区分“前方不确定”和“侧方不确定”

两个根本缺陷：

- LayerNorm 使 embedding norm 恒定  
→  $\text{score}=0$  时调制幅度不为零
- 全局调制，无空间感知

我们想要的效果：



规划器应感知“哪个区域感知不可靠”，主动规避

# BEV 不确定性热力图：零参数空间化

核心思路：用图像质量指标 + QT-Former attention 替代“压缩为全局向量”的信息流

**Step 1:** per-patch quality (无需学习)

$$q_j = f(\underbrace{\text{Laplacian\_var}}_{\text{边缘清晰度}}, \underbrace{\text{Gradient\_mag}}_{\text{纹理丰富度}}, \underbrace{\text{Contrast}}_{\text{雾天对比度}})$$

**Step 2:** 通过 attention 传播到 BEV

$$u_i = \sum_j \underbrace{a_{ij}}_{\text{QT-Former attn}} \cdot (1 - q_j)$$

600+300 个 learned query (非规则网格)

**Step 3:** k-NN 空间插值 (k=5)

$$c_m = \text{mean}_t \text{ knn}(U, \text{ref\_xy}, \text{wp}_{m,t})$$

实施可行性:

| 部分               | 硬件      |
|------------------|---------|
| patch quality 计算 | CPU     |
| BEV map 提取       | 16GB 本地 |
| λ 训练             | CPU     |
| FiLM 重训          | A100    |
| 闭环评估             | A100    |

**BEV map 提取不需要 LLM**

仅需 EVAViT + QT-Former

≈ **0.73 GB** 显存

## 诊断与下一步

---

## 后续工作路线图

| 时间      | 任务                         | 资源   | 交付物            |
|---------|----------------------------|------|----------------|
| 第 1 周   | 信号验证 + BEV map 提取          | 本地   | 热力图可视化         |
| 第 1 周   | Score-Gated 代码实现           | 本地   | 代码             |
| 第 2 周   | $\lambda$ 训练与 mode cost 验证 | 本地   | $\lambda$ + 结果 |
| 第 2-3 周 | Score-Gated FiLM 重训        | A100 | Checkpoint     |
| 第 3 周   | UQ 消融 + FiLM 消融            | A100 | 消融表            |
| 第 3-4 周 | 7 组完整闭环评估                  | A100 | 主实验表           |
| 第 4-6 周 | 论文撰写                       | 本地   | 完整初稿           |

本地可立即推进 (16GB):

前 2 周的工作全部可在本地完成

申请服务器资源:

~103h A100 GPU 时间

## FiLM + BEV Cost 消融 (关键):

| 组 | 配置              | SG | BEV<br>Cost |
|---|-----------------|----|-------------|
| A | Baseline        | —  | —           |
| B | FiLM-v3         | ×  | —           |
| C | Score-<br>Gated | ✓  | —           |
| D | BEV Cost        | —  | 空间          |
| E | Full            | ✓  | 空间          |
| F | <b>Global</b>   | —  | 全局          |
| G | <b>C+F</b>      | ✓  | 全局          |

D vs F & E vs G = 空间性证明

## UQ 组件消融:

| 消融              | 说明             |
|-----------------|----------------|
| Full model      | 完整 UQEstimator |
| w/o stat        | 去掉统计特征         |
| w/o decoder     | mean pool 替代   |
| w/o ranking     | 仅 MSE+cal      |
| w/o calibration | 仅 MSE+rank     |

指标: L2@3s, Col@3s

按 normal / adverse 分组

## 技术可行性：高

- UQ 估计已验证 (AUROC 0.954)
- FiLM 机制已验证 (CoI -23%)
- Score-Gated 改动量小 (3 文件 ~12 行)
- Phase -1: 4/5 项已确认
- Plan anchor 多样性充分 ( $\text{IoU} < 0.5$ )

## 风险与修正

- ~~Score-Gated 不解决退化~~
- 已排除: UQ score 双峰
- ~~BEV query 非网格~~
- 已修正: k-NN 替代双线性
- Flash Attention 阻断 attn
- 已确认: 临时关闭即可

## 总结

---

# 总结

1. 发现：VLM 驾驶在恶劣天气下碰撞率放大  $161\times$ ，  
开环 L2 指标无法反映——L2 精度与安全性正交
2. 已有成果：UQ 估计 (AUROC=**0.954**) + FiLM 碰撞感知训练 (Col -**23%**)  
当前问题：Normal ADE +116%，根因：FiLM 调制的空间盲目性
3. **Phase -1 验证**：修正 BEV query 布局 (learned  $\rightarrow$  k-NN)、poses\_cls 类型 (sigmoid  $\rightarrow$  乘法门控) 等关键假设
4. 新方向：BEV 不确定性热力图
  - patch 图像质量  $\xrightarrow{\text{QT-Former attn}}$  BEV 空间不确定性场
  - k-NN 插值 + 乘法门控注入轨迹 mode 选择
  - 核心计算无需 LLM，16GB 本地可运行
  - 7 组消融 (含 G 组验证空间 vs 全局)
5. 轻量侧信道注入：参数增量  $< 0.5\text{M}$ ，适用于任意冻结的端到端驾驶模型

谢谢！

备用：逐天气场景详细数据 i

| 天气              | 样本  | UQ    | L2@3s | Col@3s |
|-----------------|-----|-------|-------|--------|
| ClearNoon       | 906 | 0.003 | 1.554 | 0.02%  |
| ClearSunset     | 688 | 0.746 | 1.581 | 0.00%  |
| CloudyNoon      | 824 | 0.885 | 3.890 | 0.02%  |
| CloudySunset    | 291 | 0.794 | 2.559 | 0.00%  |
| HardRainSunset  | 717 | 0.936 | 3.968 | 2.09%  |
| HardRainNoon    | 388 | 0.984 | 1.954 | 0.00%  |
| MidRainyNoon    | 714 | 0.993 | 2.540 | 0.68%  |
| MidRainyNight   | 537 | 0.981 | 1.051 | 0.53%  |
| SoftRainNight   | 632 | 0.820 | 1.033 | 1.50%  |
| WetCloudyNoon   | 431 | 0.989 | 1.593 | 0.27%  |
| WetCloudySunset | 409 | 0.940 | 2.843 | 0.49%  |
| FoggyNoon       | 354 | 0.929 | 2.255 | 0.00%  |
| FoggySunset     | 962 | 0.876 | 0.855 | 0.00%  |
| ClearNight      | 508 | 0.235 | 1.181 | 0.00%  |

## 备用：参数预算

| 模块          | 位置        | 参数量          | 说明                                             |
|-------------|-----------|--------------|------------------------------------------------|
| UQEstimator | 独立模块      | 2.21M        | Transformer decoder + MLP                      |
| FiLM L1     | QT-Former | 0.13M        | $\text{Linear}(256 \rightarrow 256) \times 2$  |
| FiLM L2     | VAE       | 2.11M        | $\text{Linear}(256 \rightarrow 4096) \times 2$ |
| 合计          |           | <b>4.45M</b> | <b>ORION 主干的 0.45%</b>                         |