

视觉骨干不确定性感知规划

从密度不确定性估计到大模型前视觉适配器


2026 年 6 月

1. 为什么需要视觉骨干不确定性？
2. 0521 方案为什么需要调整？
3. 新方案如何让 UQ 进入大模型决策链路？
4. 目前实验说明了什么，还没有说明什么？

问题与路线调整

问题：L2 看不见安全风险

ORION 流程



0521 观察

- 恶劣天气下碰撞风险显著上升
- L2 误差不一定同步变差
- 模型缺少“我看不清”的自我感知

核心问题

视觉质量下降时，规划器仍可能过度自信。


0521 方案的说服力问题

0521 方案	优点	问题
手工 UQ 估计器 L2/解码器 FiLM 碰撞/L2 改善	可以输出分数与表征向量 容易直接改变轨迹 有可观测效果	伪标签人为设定，理论依据弱 像绕过大模型的后端控制器 难证明是大模型利用了 UQ

本阶段调整

把主张从“我用 UQ 改轨迹”改成“我把可靠性条件化后的视觉证据交给大模型，让大模型仍然做规划决策”。

方法演进：从后端调制到大模型前视觉适配



当前主线：密度不确定性估计负责**监测视觉骨干不确定性**，大模型前视觉适配器负责**条件化视觉证据**。

方法

密度不确定性估计：替代人为 UQ 估计器

原接口保留



EVAViT 特征 $\rightarrow$ (分数, 表征向量)

含义改变

- 分数：偏离正常视觉特征流形的程度
- 表征向量：有效密度方向，兼容 256 维旧接口
- 理论基础：特征密度/OOD 检测，而不是人为伪标签


指标	数值
AUROC	0.799
AUPRC	0.951
路线置信区间	0.675–0.915
有效维度	16
兼容维度	256

密度不确定性估计结果



结论：密度不确定性估计可以作为视觉条件退化的监测信号，但它本身还不是规划策略。

先试过：显式 UQ 词元




设置	可靠性问答	规划
正确 UQ	解析率/准确率 0.97/0.90	ADE 0.2447
打乱 UQ	解析率/准确率 0.99/0.96	ADE 0.2147
无注入	不可解析	ADE 0.1910

诊断

大模型能读懂可靠性语义，但没有规划监督时，这个语义不会自然转化为更好轨迹。

$$q' = q + s_{\text{UQ}} \cdot \text{up}(\text{GELU}(\text{down}(\text{LN}(q))))$$

- 作用在大模型前视觉查询向量
- 不直接接触 VAE/轨迹解码器
- up 零初始化，初始严格恒等
- 可做正确/打乱/无注入因果对照




$$d(\text{受损} + \text{正确 UQ}, \text{正常参考}) < d(\text{受损} + \text{打乱 UQ}, \text{正常参考})$$

- 不手工规定“高 UQ 就刹车”
- 正常/受损是同一场景，几何和专家轨迹一致
- 当前扰动：单相机丢失强度 1
- 目标：受损视觉下，正确 UQ 帮助恢复接近正常输入的规划表示

实验结果

路线均衡受损输入评估：平均有效

模式	ADE	FDE
无注入	1.4429	2.5210
零值注入	1.4429	2.5210
打乱 UQ	1.2286	2.1969
正确 UQ	1.1641	2.0955




10 条路线，每条 35 个有效规划帧，共 350 样本。

关键结论

正确 UQ 相比无注入：ADE 改善 19.3%；正确 UQ 相比打乱 UQ：ADE 改善 5.3%。正确 UQ 有额外价值。

路线级结果：有效但不稳定




正确 UQ 相比无注入在 9/10 条路线改善；相比打乱 UQ 在 8/10 条路线改善。失败边界主要出现在 YieldToEmergencyVehicle 和部分复杂路口。

高低 UQ 分层：不能过度声称

分组	无注入	打乱 UQ	正确 UQ
高 UQ	1.673	1.526	1.502
低 UQ	1.262	1.089	1.052

正确 UQ 在两组都优于打乱 UQ，但收益没有集中在高 UQ。




谨慎表述

当前只能说 UQ 是有效条件信号，不能说分数越高收益越大。

正常输入安全性：ADE 安全，FDE 需约束

模式	ADE	FDE
无注入	0.8884	1.3707
打乱 UQ	0.9008	1.4265
正确 UQ	0.8971	1.4248


正确 UQ 相比无注入：ADE 退化 1.0%，
FDE 退化 4.0%。



下一步要求

加入正常输入保持损失或恒等正则，把正常输入 FDE 退化压回 3% 以内。

可视化：轨迹行为确实会被改变



GIF 用于展示适配器改变规划行为；定量结论仍以路线均衡表格为准。

结论与计划

当前能说什么，不能说什么

可以说

- 密度不确定性估计比手工 UQ 估计器更有理论依据
- 大模型能读取 UQ 词元的可靠性语义
- 大模型前视觉适配器在路线均衡受损输入评估上平均有效
- 正确 UQ 优于打乱 UQ

暂时不能说

- 显式 UQ 词元已经改善规划
- 高 UQ 场景收益一定更大
- 适配器已经稳定泛化
- 正常场景完全无退化

下一阶段最短路线

任务	目标	通过标准
路线均衡训练	500–1000 配对样本，仅训练适配器	正确 UQ 稳定优于打乱 UQ
正常输入保持	加入恒等/保持损失	正常输入 ADE/FDE 退化 $< 3\%$
表征向量条件 路线分层	分数和密度表征向量同时注入 按路线/天气/受损强度拆分	分层结果更可解释 明确收益和失败边界

1. 0521 证明了“需要 UQ”，但旧方案说服力不足。
2. 本阶段用密度不确定性估计替换手工 UQ 估计器，保留分数与表征向量接口。
3. 显式 UQ 词元给出重要负结果：读懂语义不等于改善规划。
4. 大模型前视觉适配器是当前主线：不直接改轨迹，而是条件化大模型前的视觉证据。
5. 路线均衡实验已有平均收益，但下一步要解决稳定性和正常输入 FDE。

谢谢

备用：逐路线 ADE

路线	无注入	打乱 UQ	正确 UQ	正确相对打乱
VanillaSignalizedTurnEncounterRedLight	2.174	1.049	0.754	+28.1%
OppositeVehicleRunningRedLight	0.689	0.504	0.436	+13.5%
HighwayExit	0.747	0.606	0.533	+12.0%
VehicleTurningRoute	0.728	0.601	0.555	+7.7%
AccidentTwoWays	0.199	0.158	0.152	+3.8%
BlockedIntersection	2.366	1.956	1.873	+4.2%
SignalizedJunctionLeftTurnEnterFlow	0.886	0.814	0.829	-1.9%
NonSignalizedJunctionLeftTurnEnterFlow	1.742	1.721	1.650	+4.1%
LaneChange	1.420	1.381	1.362	+1.4%
YieldToEmergencyVehicle	3.477	3.496	3.496	-0.0%