

UQ-ORION

面向恶劣天气的不确定性感知端到端自动驾驶安全扩展

2026 年 4 月 1 日

1. 研究动机
2. 技术方案
3. 实验结果
4. 问题分析与改进方向
5. Phase -1 可行性验证
6. 新方向：BEV 不确定性热力图
7. 下一步计划

研究动机

ORION: VLM-based 端到端自动驾驶


ORION (ICCV 2025) 流程:

1. 多视角图像 → EVAViT encoder
2. QT-Former 场景理解
3. Qwen VLM 推理 + 规划
4. VAE 解码 → 轨迹

优势: 利用 VLM 的世界知识做驾驶决策

问题: 在恶劣天气下**过度自信**

- 不知道“自己看不清了”
- 依然做出激进决策



核心发现：恶劣天气碰撞率放大 161×

指标	Normal	Adverse	倍数
L2@3s	2.38m	1.78m	0.75×
Col@1s	0.02%	1.78%	89×
Col@3s	0.01%	1.61%	161×

反直觉发现


- 恶劣天气的 L2 误差反而更低（低速 → 短轨迹 → 天然低 L2）
- 但碰撞率高出 **161** 倍
- **L2 轨迹精度** ≠ 安全性，开环指标看不出问题

数据来源：Bench2Drive 验证集，12,806 个样本（开环评估）

Adverse 判定：Weather ID $\notin \{0, 1, 2, 3\}$ ，即非 ClearNoon/ClearSunset/CloudyNoon/CloudySunset 的所有条件 3/20

技术方案

整体架构：轻量 UQ + 双层 FiLM 注入



设计原则：

- 零主干微调
- 新增参数 4.45M（主干的 0.45%）
- 一行开关切换

FiLM 调制： $\text{out} = \gamma \odot \text{in} + \beta$

- L1：调制场景理解
- L2：调制轨迹规划
- Identity 初始化保证无损

UQEstimator: 从视觉特征估计不确定性

输入:

- Patch tokens $[B, 6, 1600, 1024]$
- 5 维统计特征 (激活值、熵、跨视角一致性)

架构:

1. Patch 投影 $1024 \rightarrow 256$
2. 2 层 TransformerDecoder
(16 learnable queries cross-attend patches)
3. 统计特征分支 $5 \rightarrow 64$
4. 融合 $[256 + 64] \rightarrow 512 \rightarrow 256$
5. 双输出头: score + embedding

训练:

- 伪标签监督 (weather-based)
- 损失: MSE + calibration + ranking
- 12,806 样本, 256 patch 子采样
- **Epoch 2 即收敛**

性能:

- 参数量: **2.21M**
- Spearman $\rho = \mathbf{0.97}$
- 训练时间: $\sim 100\text{min}$
- 显存: $< 5\text{GB}$

碰撞感知 FiLM 训练

传统 L2 loss 训练的 FiLM 无法降低碰撞率（反而 +4.3%），因此我们设计了碰撞感知训练目标：

$$\mathcal{L}_{\text{FiLM}} = \mathcal{L}_{\text{plan}} + 0.5 \cdot \underbrace{\mathbb{E} [\text{ReLU}(m - d_{\min}) \cdot s_{\text{UQ}}]}_{\text{UQ-weighted collision margin loss}}$$

关键设计：

- Margin $m = 4.0\text{m}$ (≈ 2 车身宽度)
- UQ score 作为权重 (detached)
高不确定性 $\rightarrow$ 更强碰撞惩罚
- 冻结 ORION 主干，只训 FiLM

Margin 选择实验：

Margin	有效帧	说明
2.0m	$\sim 0\%$	无梯度信号
4.0m	$\sim 30\%$	合理
5.0m	$\sim 60\%$	过于激进

实验结果

UQ Score: Normal vs Adverse 分离度

	Normal	Adverse
UQ 均值	0.023	0.893
UQ 中位数	0.00008	0.970
Gap	0.870	
AUROC	0.954	


ClearNoon: 0.0001

CloudyNoon: 0.072


MidRainyNoon: 0.231

HardRainNight: 0.989


MidRainSunset: 0.997



逐天气 UQ 分布



UQ Score vs 规划质量



相关性分析:

指标	值
Spearman(UQ, L2)	$\rho = 0.301$
Pearson(UQ, L2)	$r = 0.182$
Spearman(UQ, Col)	$\rho = -0.077$

解读:

- UQ 捕获了感知质量下降
- 但无法直接翻译为碰撞风险
- 需要碰撞感知 loss 桥接

闭环评估：50 场景 Baseline vs FiLM

指标	Baseline	FiLM v3	变化
ALL (50) Col@3s	0.66%	0.52%	-21%
ALL ADE@3s	2.46m	4.44m	+80%
Normal (11) Col@3s	0.05%	0.11%	+0.06%
Normal ADE@3s	2.78m	6.00m	+116%
Adverse (39) Col@3s	0.83%	0.64%	-23%
Adverse ADE@3s	2.37m	4.00m	+69%

碰撞率改善：

- 恶劣天气碰撞率 -23%
- 高风险场景改善最大

已知问题：

- Normal ADE +116%
- 根因：FiLM 未做 score 门控
- Score-Gated 代码完成，待重训

10/20

注：回放式闭环评估（Replay-Based），非真实 CARLA 仿真。模型行为不影响后续帧，始终使用 GT ego pose，

L2 Loss FiLM vs 碰撞感知 FiLM

	L2 Loss FiLM	Collision-Aware FiLM
Adverse Col@3s	1.22% (+4.3%)	0.64% (-23%)
ADE@3s	3.90m (+73%)	4.44m (+80%)

Insight: L2 优化 $\neq$ 安全优化

- 纯 L2 loss 训练的 FiLM 让碰撞率上升 4.3%
- L2 降低 = 更好地拟合训练分布，但分布本身不含安全信号
- 必须引入碰撞感知目标才能提升安全性

问题分析与改进方向

关键问题：Normal 场景 ADE 退化 +116%

现象：Normal 场景 UQ score ≈ 0 ，FiLM 不应有调制，但 ADE 从 2.78m $\rightarrow$ 6.00m

根因：embed_head 的 LayerNorm 使所有样本 embedding $\|\mathbf{e}\| \approx \sqrt{256}$

$$\gamma = W_\gamma \cdot \underbrace{\text{emb}}_{\|\cdot\| \approx 16} + b_\gamma \implies \text{Normal 和 Adverse 调制幅度相当}$$

修复方案：Score-Gated FiLM

$$\gamma = 1 + \underbrace{s}_{\text{score}} \cdot (\gamma_{\text{raw}} - 1)$$

$$\beta = s \cdot \beta_{\text{raw}}$$

$$s \rightarrow 0 : \gamma \rightarrow 1, \beta \rightarrow 0 \quad (\text{identity})$$

$$s \rightarrow 1 : \gamma \rightarrow \gamma_{\text{raw}}, \beta \rightarrow \beta_{\text{raw}}$$

改动量：3 个文件 $\sim$ 12 行代码 + FiLM 重训

“保守捷径”现象

观察：

- Brake MAE +129%
- Throttle MAE +74%
- 模型学会“更慢、更停、更让”
- 碰撞降低但效率退化

本质：安全 vs 效率的权衡（Pareto tradeoff），而非纯改善

第二轮训练方向：

1. 堵捷径：

- 引入进度/速度保持约束
- 舒适性（acc/jerk）正则

2. 门控：

- Score-Gated FiLM
- 低 UQ → 轨迹质量优先
- 高 UQ → 安全优先

3. 约束幅度：

- $\|\gamma - 1\|$ 和 $\|\beta\|$ 正则
- 防止过强调制

Phase –1 可行性验证

Phase –1: 关键假设验证（本地完成）

Q	假设	结论	影响
Q1	attn_weights 可提取	Flash Attn 阻断	临时关闭即可
Q2	BEV query 30×30 网格	600+300 learned	双线性 → k-NN
Q3	poses_cls 为 softmax	sigmoid scores	减法 → 乘法门控
Q4	anchor 空间覆盖	充分 (IoU<0.5: 89%)	BEV cost 有区分力
Q5	16GB 可部分加载	待服务器验证	—

确认的有利条件:

- UQ score 高度双峰
Normal ≈ 0 , Adverse ≈ 0.97
- Score-Gated FiLM 安全可行
- 20 mode 空间展幅 25.7m × 51.9m

修正的错误假设:

- BEV query 非规则网格
→ k-NN 空间插值 (k=5)
- poses_cls 非 softmax
→ 乘法门控替代 logit 减法
- Score-Gated 涉及 3 文件
(非 2 文件, ~12 行非 6 行)

新方向：BEV 不确定性热力图

现有 FiLM 的空间盲目性

当前信息流失过程：


1. $\text{patch_tokens} [B, 6, 1600, 1024]$
2. $\text{cross-attention} \rightarrow \text{attn_weights}$ （空间信息在此丢失）
3. **mean pool** $\rightarrow \text{emb} [B, 256]$
4. FiLM 对所有 BEV query 施加相同调制

结果：无法区分“前方不确定”和“侧方不确定”

两个根本缺陷：

- LayerNorm 使 embedding norm 恒定
→ $\text{score}=0$ 时调制幅度不为零
- 全局调制，无空间感知

我们想要的效果：



规划器应感知“哪个区域感知不可靠”，主动规避

BEV 不确定性热力图：零参数空间化

核心思路：用图像质量指标 + QT-Former attention 替代“压缩为全局向量”的信息流

Step 1: per-patch quality (无需学习)

$$q_j = f(\underbrace{\text{Laplacian_var}}_{\text{边缘清晰度}}, \underbrace{\text{Gradient_mag}}_{\text{纹理丰富度}}, \underbrace{\text{Contrast}}_{\text{雾天对比度}})$$

Step 2: 通过 attention 传播到 BEV

$$u_i = \sum_j \underbrace{a_{ij}}_{\text{QT-Former attn}} \cdot (1 - q_j)$$

600+300 个 learned query (非规则网格)

Step 3: k-NN 空间插值 (k=5)

$$c_m = \text{mean}_t \text{ knn}(U, \text{ref_xy}, \text{wp}_{m,t})$$

实施可行性:

部分	硬件
patch quality 计算	CPU
BEV map 提取	16GB 本地
λ 训练	CPU
FiLM 重训	A100
闭环评估	A100

BEV map 提取不需要 LLM

仅需 EVAViT + QT-Former

≈ 0.73 GB 显存

下一步计划

后续工作路线图

时间	任务	资源	交付物
第 1 周	信号验证 + BEV map 提取	本地	热力图可视化
第 1 周	Score-Gated 代码实现	本地	代码
第 2 周	λ 训练与 mode cost 验证	本地	λ + 结果
第 2-3 周	Score-Gated FiLM 重训	A100	Checkpoint
第 3 周	UQ 消融 + FiLM 消融	A100	消融表
第 3-4 周	7 组完整闭环评估	A100	主实验表
第 4-6 周	论文撰写	本地	完整初稿

本地可立即推进 (16GB):

前 2 周的工作全部可在本地完成

申请服务器资源:

~103h A100 GPU 时间

FiLM + BEV Cost 消融 (关键):

组	配置	SG	BEV Cost
A	Baseline	—	—
B	FiLM-v3	×	—
C	Score- Gated	✓	—
D	BEV Cost	—	空间
E	Full	✓	空间
F	Global	—	全局
G	C+F	✓	全局

D vs F & E vs G = 空间性证明

UQ 组件消融:

消融	说明
Full model	完整 UQEstimator
w/o stat	去掉统计特征
w/o decoder	mean pool 替代
w/o ranking	仅 MSE+cal
w/o calibration	仅 MSE+rank

指标: L2@3s, Col@3s

按 normal / adverse 分组

技术可行性：高

- UQ 估计已验证 (AUROC 0.954)
- FiLM 机制已验证 (CoI -23%)
- Score-Gated 改动量小 (3 文件 ~12 行)
- Phase -1: 4/5 项已确认
- Plan anchor 多样性充分 ($\text{IoU} < 0.5$)

风险与修正

- ~~Score-Gated 不解决退化~~
- 已排除: UQ score 双峰
- ~~BEV query 非网格~~
- 已修正: k-NN 替代双线性
- Flash Attention 阻断 attn
- 已确认: 临时关闭即可

总结

总结

1. 发现：VLM 驾驶在恶劣天气下碰撞率放大 $161\times$ ，
开环 L2 指标无法反映——L2 精度与安全性正交
2. 已有成果：UQ 估计 (AUROC=**0.954**) + FiLM 碰撞感知训练 (Col -**23%**)
当前问题：Normal ADE +116%，根因：FiLM 调制的空间盲目性
3. **Phase -1 验证**：修正 BEV query 布局 (learned $\rightarrow$ k-NN)、poses_cls 类型
(sigmoid $\rightarrow$ 乘法门控) 等关键假设
4. 新方向：BEV 不确定性热力图
 - patch 图像质量 $\xrightarrow{\text{QT-Former attn}}$ BEV 空间不确定性场
 - k-NN 插值 + 乘法门控注入轨迹 mode 选择
 - 核心计算无需 LLM，16GB 本地可运行
 - 7 组消融 (含 G 组验证空间 vs 全局)
5. 轻量侧信道注入：参数增量 $< 0.5\text{M}$ ，适用于任意冻结的端到端驾驶模型

谢谢！

备用：逐天气场景详细数据 i

天气	样本	UQ	L2@3s	Col@3s
ClearNoon	906	0.003	1.554	0.02%
ClearSunset	688	0.746	1.581	0.00%
CloudyNoon	824	0.885	3.890	0.02%
CloudySunset	291	0.794	2.559	0.00%
HardRainSunset	717	0.936	3.968	2.09%
HardRainNoon	388	0.984	1.954	0.00%
MidRainyNoon	714	0.993	2.540	0.68%
MidRainyNight	537	0.981	1.051	0.53%
SoftRainNight	632	0.820	1.033	1.50%
WetCloudyNoon	431	0.989	1.593	0.27%
WetCloudySunset	409	0.940	2.843	0.49%
FoggyNoon	354	0.929	2.255	0.00%
FoggySunset	962	0.876	0.855	0.00%
ClearNight	508	0.235	1.181	0.00%

备用：参数预算

模块	位置	参数量	说明
UQEstimator	独立模块	2.21M	Transformer decoder + MLP
FiLM L1	QT-Former	0.13M	$\text{Linear}(256 \rightarrow 256) \times 2$
FiLM L2	VAE	2.11M	$\text{Linear}(256 \rightarrow 4096) \times 2$
合计		4.45M	ORION 主干的 0.45%