

UQ-ORION: 面向恶劣天气的不确定性感知端到端自动驾驶安全扩展

研究进展报告

2026 年 4 月 1 日

摘要

本报告总结 UQ-ORION 项目的当前进展。该项目在 ORION (ICCV 2025) 端到端自动驾驶框架的基础上,通过轻量不确定性量化(UQ)模块和 FiLM 条件调制机制,提升模型在恶劣天气场景(雨、雾、夜间)下的安全性。

截至目前,我们已完成 UQEstimator 训练(AUROC=0.954)、FiLM 双层注入、碰撞感知训练、以及 50 场景闭环评估。实验表明恶劣天气下碰撞率降低 21%–23%,但存在正常场景轨迹退化问题(ADE +116%),已定位根因(FiLM 调制的空间盲目性与 LayerNorm 范数崩塌)。

在此基础上,我们完成了 Phase -1 可行性验证(5 项中 4 项已确认),发现了若干关键的计划假设偏差: BEV query 并非 30×30 规则网格而是 $600 + 300$ 个 learned embedding; poses_cls 采用 sigmoid focal loss (非 softmax); Flash Attention 阻断 attention weights 提取但有明确缓解方案。本报告据此修正技术路线,提出以 k-NN 空间插值替代双线性采样、以乘法门控替代 logit 减法的 BEV 不确定性代价注入方案。

目录

1	研究背景与动机	4
1.1	问题定义	4
1.2	研究目标	4
2	技术方案	5
2.1	整体架构	5
2.2	UQEstimator 模型	5

2.3	FiLM 双层注入	6
2.4	当前 FiLM 方案的根本局限	6
2.5	伪标签设计的自洽性	6
2.6	损失函数设计	7
2.7	参数预算	7
3	当前进展	8
3.1	完成阶段概览	8
3.2	Phase -1 可行性验证结果	8
3.2.1	关键修正	9
3.2.2	补充发现: UQ Score 高度双峰分布	9
3.2.3	补充发现: Plan Anchor 空间多样性充分	10
3.3	实验结果	10
3.3.1	天气分类判定依据	10
3.3.2	UQ Score 分离度 (v3, weather-based 分类)	11
3.3.3	闭环评估结果 (50 场景, 修复 init_weights 后)	11
3.3.4	Baseline 规划指标分析	12
4	遇到的问题与解决方案	13
4.1	问题 1: 伪标签分类不一致 (已解决)	13
4.2	问题 2: init_weights 覆盖 FiLM Identity Init (已修复)	13
4.3	问题 3: Normal 场景 ADE 严重退化 (待解决)	13
4.4	问题 4b: 评估体系约束	14
4.5	问题 5: FiLM 的“保守捷径”现象	14
5	后续工作规划	14
5.1	第一阶段: 修复现有方案 (1-2 周, 本地 16GB 可完成)	14
5.1.1	Score-Gated FiLM 实现与重训	14
5.1.2	信号有效性验证 (Phase 0, 无 GPU 需求)	15
5.2	第二阶段: BEV 不确定性热力图 (核心新贡献, 2-4 周)	15
5.2.1	核心思路	15
5.2.2	计算流程 (零额外参数)	16
5.2.3	lambda 训练目标	17
5.3	第三阶段: 完整消融实验 (需申请服务器)	17
5.3.1	消融实验矩阵	17
5.3.2	UQ 组件消融	18
5.4	长期目标	18

6	资源需求	18
6.1	计算资源	18
6.2	存储资源	19
6.3	软件环境	19
7	可行性分析	19
7.1	技术可行性	19
7.2	风险评估	20
7.3	创新点与论文贡献	20
8	时间规划	21
9	总结	21

1 研究背景与动机

1.1 问题定义

ORION 是一个基于 VLM (Vision-Language Model) 的端到端自动驾驶框架，在标准场景下表现优秀。其核心流程为：

Vision Encoder $\rightarrow$ QT-Former $\rightarrow$ VLM $\rightarrow$ Planning Token $\rightarrow$ VAE $\rightarrow$ 轨迹

然而，VLM-based planner 存在一个关键缺陷：**在恶劣天气（雨、雾、夜间）等 OOD 场景下过度自信**，无法感知自身感知质量的下降，从而做出激进的轨迹决策。

通过对 Bench2Drive 验证集（12,806 个样本）的分析，我们发现了一个令人警醒的统计事实：

核心发现：恶劣天气碰撞率放大效应

- 恶劣天气碰撞率是正常天气的 **161 倍** (1.61% vs 0.01%)
- 但恶劣天气的 L2 轨迹误差反而**低于**正常天气 (1.78m vs 2.38m)
- 模型「看起来精度不错」但实际碰撞风险剧增

这一发现揭示了传统开环 L2 评估指标的局限性——轨迹精度与安全性是两个不同维度的概念。

1.2 研究目标

在不微调 ORION 主干（~1B 参数，36GB 模型文件）的前提下，设计一个轻量即插即用的不确定性感知安全扩展方案：

1. **量化感知不确定性**：训练轻量 UQ 估计器，从视觉 token 提取每帧的不确定性分数与嵌入
2. **空间化不确定性**：将不确定性从全局标量升维为 BEV 空间热力图，使规划器感知”哪个区域的感知不可靠”
3. **约束轨迹决策**：用不确定性代价约束多模态轨迹模式选择，主动规避感知可靠性低的区域

约束条件：新增参数 < 5M，零主干微调，轻量侧信道注入（在冻结层的激活值上施加 FiLM 调制，适用于任意冻结的端到端驾驶模型）。

2 技术方案

2.1 整体架构




图 1: UQ-ORION 整体架构。灰色部分为 ORION 原有冻结模块，蓝色为本项目新增模块。

2.2 UQEstimator 模型

UQEstimator 接收 EVAViT 的 patch tokens 和 5 维统计特征，输出不确定性 score $\in [0, 1]$ 和 256 维 embedding。

模型结构：

- **Patch 投影**：Linear(1024 $\rightarrow$ 256)，降维控制参数量
- **Cross-Attention 池化**：2 层 TransformerDecoder，16 个 learnable queries 通过 cross-attention 自适应关注最相关的 patches
- **统计特征分支**：5 维原始特征 $\rightarrow$ Linear(5 $\rightarrow$ 64) + GELU + LayerNorm
- **融合**：concat [256 + 64] $\rightarrow$ 512 $\rightarrow$ 256
- **输出头**：score_head (Sigmoid $\rightarrow$ [0, 1])，embed_head (LayerNorm $\rightarrow$ FiLM 条件向量)

总参数量：2,210,817 (2.21M)，远在 5M 预算之内。

2.3 FiLM 双层注入

FiLM (Feature-wise Linear Modulation) 通过 $\text{output} = \gamma \odot \text{input} + \beta$ 实现条件调制：

- **FiLM L1** (QT-Former 层, 0.13M)：调制检测 query，让下游 LLM 接收到“视野受限”的场景表示
- **FiLM L2** (VAE 层, 2.11M)：调制 ego_feature (规划 token)，将轨迹分布向保守模式偏移

两层 FiLM 均采用 Identity 初始化 ($\gamma = 1, \beta = 0$)，确保新增模块不破坏原有性能。

2.4 当前 FiLM 方案的根本局限

在第一阶段的实验结果中，Normal 场景 ADE 退化 +116% 揭示了当前方案的两个结构性缺陷：

缺陷一：空间盲目性。 UQEstimator 通过 mean-pool 将 6×1600 个 patch 的 cross-attention 权重压缩为 256 维全局向量，空间信息完全丢失。FiLM 对所有 BEV query 施加相同调制，无法区分“前方不确定”与“侧方不确定”。

缺陷二：LayerNorm 范数崩塌。 embed_head 末尾的 LayerNorm 使所有样本的 embedding ℓ_2 -norm 恒定 ($\approx \sqrt{256}$)。因此，FiLM 的调制强度不随 UQ score 变化，Normal 场景 (score ≈ 0) 也受到等幅调制。

这两个缺陷相互叠加，导致现有 FiLM 方案的本质是“全局风格迁移”而非“空间感知的安全规划”。后续工作针对这两点分别设计修复方案（见第 5 节）。

2.5 伪标签设计的自洽性

伪标签基于 patch token 统计特征 (max_mean/cosim/entropy) 计算，UQEstimator 也以相同特征为输入，二者存在**部分特征重用**。但以下三点保证了结论的自洽性：

1. **结构学习独立于规则**：UQEstimator 新增 2 层 TransformerDecoder (16 个 learnable queries, cross-attention)，学到统计规则之外的空间结构信息；伪标签为手工加权组合，模型为学习映射，并非同一函数
2. **外部验证独立**：AUROC=0.954 使用 weather-based scene_type 分类 (天气 ID 0-3)，该分类完全独立于伪标签生成中使用的统计权重——AUROC 是对天气感知能力的独立验证，而非循环验证
3. **迭代进步可追溯**：v1→v3 的 AUROC 迭代 (0.621→0.601→0.954) 中，v3 改进主要来源于 scene_type 分类修正 (19.4% 样本重新对齐)，而非统计特征过拟合

2.6 损失函数设计

UQEstimator 训练:

$$\mathcal{L}_{\text{UQ}} = \mathcal{L}_{\text{MSE}} + 0.1 \cdot \mathcal{L}_{\text{cal}} + 0.5 \cdot \mathcal{L}_{\text{rank}} \quad (1)$$

其中 $\mathcal{L}_{\text{cal}}$ 为校准正则项 (惩罚 score 标准差过小), $\mathcal{L}_{\text{rank}}$ 为 pairwise margin ranking loss。

FiLM 碰撞感知训练:

$$\mathcal{L}_{\text{FiLM}} = \mathcal{L}_{\text{plan}} + \lambda_{\text{col}} \cdot \mathcal{L}_{\text{col}} \quad (2)$$

其中碰撞 loss 为 UQ score 加权的 hinge margin loss:

$$\mathcal{L}_{\text{col}} = \mathbb{E} [\text{ReLU}(m - d_{\min}) \cdot s_{\text{UQ}}], \quad m = 4.0\text{m}, \quad \lambda_{\text{col}} = 0.5 \quad (3)$$

2.7 参数预算

表 1: 新增模块参数量

模块	位置	参数量	说明
UQEstimator	独立模块	2,210,817 (2.21M)	Transformer decoder + MLP
FiLM L1 ($\gamma + \beta$)	QT-Former	131,584 (0.13M)	Linear(256 $\rightarrow$ 256) $\times$ 2
FiLM L2 ($\gamma + \beta$)	VAE 前	2,105,344 (2.11M)	Linear(256 $\rightarrow$ 4096) $\times$ 2
合计		4,447,745 (4.45M)	ORION 主干的 0.45%

3 当前进展

3.1 完成阶段概览

表 2: 项目流水线各阶段状态

阶段	内容	状态	关键产出
Stage 0	特征提取 (EVAViT)	完成	12,806 样本, 235GB
Stage 1a	伪标签生成 (v3)	完成	AUROC 0.954
Stage 1b	UQEstimator 训练	完成	Spearman ρ =0.97
Stage 2a	开环评估 + UQ hook	完成	12,806 样本全量
Stage 2b	FiLM L1/L2/L1+L2 训练	完成	Normal ADE +116%, Score-Gated 代码完成待重
Stage 3	碰撞感知 FiLM 训练	完成	Col-21%
Stage 4	50 场景闭环评估	完成	含 Baseline 对照
可视化	5 张图 + 18 个 GIF	完成	论文级可视化
Phase -1	可行性验证 (5 项)	4/5 完成	计划修正 + 报告
下一步	Score-Gated FiLM	待实现	修复 Normal 退化
下一步	UQ 组件消融	待实验	4 组消融对比

3.2 Phase -1 可行性验证结果

在推进 BEV 不确定性热力图方案之前,我们在本地 (Apple M3 / 16GB / 无 CUDA) 完成了 5 项关键假设的验证。结果导致了若干重要的计划修正。

表 3: Phase -1 可行性验证总结

Q	问题	结论	状态
Q1	Flash Attention 是否阻断 attn_weights?	是, 5 个 transformer 组件均 flash_attn=True。缓解: 提取时临时覆盖为 False	已确认
Q2	BEV query 是否 30×30 网格?	否。600 main + 300 propagated 个 nn.Embedding, learned positions	需服务器
Q3	poses_cls 值分布	本地无 per-frame 数据。Sigmoid focal loss ($\gamma = 2$), 推测一高多低分布	待服务器
Q4	Plan anchor 空间覆盖	充分。 $\pm 13\text{m}$ lateral $\times$ 52m forward, 88.9% mode pair IoU < 0.5	已确认
Q5	16GB 能否仅加载 EVAViT + QT-Former?	本地无 checkpoint, 两种方案待验证	待服务器

3.2.1 关键修正

基于 Phase -1 发现, 以下计划假设被修正:

- BEV query 布局:** 原假设 900 个 query 排列在 30×30 规则网格上, 实际为 600 main (nn.Embedding(600,3)) + 300 propagated (nn.Embedding(300,3)) 个 learned 位置。**双线性采样不可用**, 改用基于 reference_points 坐标的 k-NN 空间插值 ($k=5$)。
- poses_cls 类型:** 原假设为 softmax logits, 实际为 sigmoid focal loss 训练的独立 scores。Mode 选择为 $\text{argmax}(\text{poses_cls})$ 。**logit 空间减法不适用** (sigmoid 极端值对减法不敏感), 改用乘法门控。
- attn_weights shape:** $[B, 900, 9600] \rightarrow [B, 600, 9600]$ (600 main queries 参与 cross-attention, 300 propagated 需 hook 验证)。显存估算从 34MB/sample 降至 23MB/sample。
- Score-Gated FiLM 改动范围:** 原估 2 个文件约 6 行, 修正为 3 个文件约 12 行 (新增 orion_head.py 传递 uncertainty_score)。

3.2.2 补充发现: UQ Score 高度双峰分布

对 12,806 帧 eval 数据分析确认 UQ score 呈高度双峰分布 (Normal 中位数 ≈ 0 , Adverse 中位数 ≈ 0.97), 消除了 Score-Gated FiLM 在 Normal 场景仍被调制的风险——当 $s \rightarrow 0$ 时 FiLM 严格退化为恒等变换。

3.2.3 补充发现：Plan Anchor 空间多样性充分

对 20 个 plan anchor 的 BEV 走廊 IoU 分析 (3m 宽度): mean IoU = 0.261, 88.9% 的 mode pair IoU < 0.5。这证明 BEV uncertainty cost 在不同 mode 上会产生显著不同的值, D 组 vs F 组的对比有意义。建议 cost 计算时对后期时间步 ($t \geq 2$) 加权, 因早期展幅小、区分力弱。

详细报告见 `results/feasibility/feasibility_report.md`, 可视化见 `results/feasibility/` 目录。

3.3 实验结果

3.3.1 天气分类判定依据

Normal / Adverse 的划分由 `eval_openloop.py` 硬编码, 规则为: Weather ID $\in \{0, 1, 2, 3\} \rightarrow$ Normal, 其余 $\rightarrow$ Adverse。Weather ID 直接解析自 B2D 数据集的文件夹命名后缀 (`_WeatherN`)。

表 4: B2D 验证集完整天气 ID 映射

类别	ID	天气名称	说明
Normal	0	ClearNoon	晴天正午
	1	ClearSunset	晴天傍晚
	2	CloudyNoon	多云正午
	3	CloudySunset	多云傍晚
Adverse	5-14	Wet*/MidRain*/HardRain*/SoftRain*	湿路面、中雨、暴雨、小雨 (正午/傍晚)
	15	ClearNight	晴天夜间 (无降水, 但低光照, UQ≈0.235)
	18-23	Cloudy/Wet/MidRainy/HardRain/SoftRain Night	多云至暴雨夜间 6 种
	25-26	FoggyNoon / FoggySunset	雾天正午/傍晚

验证集共 12,806 帧: Normal 2,709 帧 (21.2%), Adverse 10,097 帧 (78.8%), 共 23 种天气 (ID 4、16、17、24 在验证集中不存在)。

边界说明: CloudyNoon / CloudySunset (ID 2/3) 归为 Normal, 因无任何降水/雾/夜间参数, 视觉降质可忽略; ClearNight (ID 15) 归为 Adverse, 因低光照对感知质量有实质影响 (UQ score 约 0.235, 介于 Normal 和强降雨场景之间)。

3.3.2 UQ Score 分离度 (v3, weather-based 分类)

表 5: UQ Score 分离度指标

指标	Normal	Adverse	Gap	目标
UQ Score 均值	0.023	0.893	0.870	> 0.1 ✓
UQ Score 中位数	0.00008	0.970	0.970	—
AUROC (adverse 检测)	—		0.954	> 0.7 ✓✓

UQ score 在天气维度上的排序完全正确 (表 6), 从 ClearNoon 的接近零到 MidRain-Sunset 的接近 1, 与视觉降质程度高度一致。

表 6: 逐天气类型 UQ Score

天气	分类	UQ Score	语义
ClearNoon	Normal	0.0001	完美感知
ClearSunset	Normal	0.0009	接近完美
CloudyNoon	Normal	0.072	轻微退化
MidRainyNoon	Adverse	0.231	中度退化
HardRainNight	Adverse	0.989	严重退化
MidRainSunset	Adverse	0.997	极端退化

3.3.3 闭环评估结果 (50 场景, 修复 init_weights 后)

评估方式说明: 回放式闭环 (非真实 CARLA 仿真)

本节所有指标来自**回放式闭环评估** (Replay-Based): 从 B2D 预录数据中选 50 条路线, 逐帧推理并与 GT 比对, **无真实仿真器反馈**。与真实 CARLA 仿真的主要区别: (1) 无反馈回路, 模型行为不改变后续观测; (2) 始终用 GT ego pose, 不累积位置漂移; (3) 碰撞基于 GT occupancy grid, 不含 sensor 噪声; (4) 其他 agent 按录制回放, 不响应 ego 行为。ADE/碰撞指标反映与 GT 的系统性偏差, 不能直接等同于真实驾驶安全指标。

表 7: 闭环评估: Baseline vs FiLM v3 (50 场景, 回放式)

指标	Baseline	FiLM v3	变化
ALL (50) Col@3s	0.66%	0.52%	-21%
ALL ADE@3s	2.46m	4.44m	+80%
Normal (11) Col@3s	0.05%	0.11%	+0.06%
Normal ADE@3s	2.78m	6.00m	+116%
Adverse (39) Col@3s	0.83%	0.64%	-23%
Adverse ADE@3s	2.37m	4.00m	+69%

结果解读

- 恶劣天气碰撞率降低 23% (0.83% → 0.64%), 符合预期
- 但正常天气 ADE 从 2.78m 退化至 6.00m (+116%), 这是当前最严重的问题
- 根因已定位: embed_head 的 LayerNorm 导致 FiLM 在 Normal 场景也产生非平凡调制

3.3.4 Baseline 规划指标分析

表 8: Baseline 开环指标 (12,806 样本)

指标	Normal	Adverse	倍数
L2@3s	2.38m	1.78m	0.75×
Col@1s	0.02%	1.78%	89×
Col@3s	0.01%	1.61%	161×

4 遇到的问题与解决方案

4.1 问题 1：伪标签分类不一致（已解决）

严重性：高 状态：已解决

现象：v2 伪标签使用场景类型 (Accident→adverse) 分类，但 eval_openloop 使用天气 ID (Weather 0-3=normal) 分类。2,481/12,806 样本 (19.4%) 分类不一致。

影响：v2 AUROC 0.993 仅在自身标签空间有效，在 eval_openloop 空间实际仅为 0.601。

解决方案 (v3)：引入 weather-based 分类对齐 eval_openloop，修正后 AUROC 提升至 **0.954**。

4.2 问题 2：init_weights 覆盖 FiLM Identity Init（已修复）

严重性：高 状态：已修复

现象：PETRTemporalTransformer.init_weights() 对所有 Linear 层执行 xavier_uniform_，覆盖了 FiLM 层精心设置的 identity 初始化 ($\gamma = 1, \beta = 0$)。

影响：未加载训练权重时 FiLM 不是 identity 而是随机调制。早期 10 场景 baseline 数据不可信。

解决方案：在 init_weights() 中用参数 ID 排除 FiLM 层。修复后重跑 50 场景 baseline 获得可信对照数据。

4.3 问题 3：Normal 场景 ADE 严重退化（待解决）

严重性： 状态：已定位根因，待实现修复

现象：Normal 场景 UQ score ≈ 0 (0.0001–0.0015)，FiLM 不应有任何调制效果，但 ADE 从 2.78m $\rightarrow$ 6.00m (+116%)。

根因：embed_head 末尾的 LayerNorm 使所有样本的 embedding ℓ_2 norm 恒定 ($\approx \sqrt{256} \approx 16$)，无论 UQ score 高低。FiLM 计算 $\gamma = W \cdot \text{emb} + b$ 时，由于 embedding norm 恒定，Normal 和 Adverse 场景的调制幅度相当。

设计方案：Score-Gated FiLM（见第 5 节）。

4.4 问题 4b：评估体系约束

类型：范围约束 状态：需论文正面交代

本报告所有闭环指标均来自回放式闭环评估（见第 2.4 节说明）。主要约束：

1. ADE/碰撞改善在真实 CARLA 仿真中的泛化性**未经验证**
2. 50 场景碰撞率均值受个别场景影响大（部分 0%，少数高达 11.25%）
3. Normal 场景 ADE 退化（+116%）尚未修复，Score-Gated checkpoint 待重训

这些约束应在论文中正面交代，并将真实 CARLA 闭环验证作为 Future Work 列出。

4.5 问题 5：FiLM 的“保守捷径”现象

严重性：中 状态：需第二轮训练解决

现象：碰撞感知训练使模型全面趋于保守（Brake MAE +129%，Throttle MAE +74%），通过“更慢、更停、更让”降低碰撞率，而非更智能的避障。

影响：ADE 增加 41–80%。部分场景（CrossingBicycleFlow）甚至因过度制动引入新碰撞。

解决方向：

1. 引入进度/舒适约束，抑制无理由降速
2. Score-Gated FiLM 实现选择性调制
3. 对 γ, β 偏离 identity 加正则约束

5 后续工作规划

5.1 第一阶段：修复现有方案（1–2 周，本地 16GB 可完成）

5.1.1 Score-Gated FiLM 实现与重训

解决 LayerNorm 范数崩塌问题，将 UQ score 直接作为调制强度的门控信号：

$$\gamma_{\text{raw}} = W_{\gamma} \cdot \text{emb} + b_{\gamma}, \quad \beta_{\text{raw}} = W_{\beta} \cdot \text{emb} + b_{\beta} \quad (4)$$

$$\gamma = 1 + s \cdot (\gamma_{\text{raw}} - 1), \quad \beta = s \cdot \beta_{\text{raw}} \quad (5)$$

当 $s \rightarrow 0$ （正常场景）时， $\gamma \rightarrow 1, \beta \rightarrow 0$ ，FiLM 退化为恒等变换；当 $s \rightarrow 1$ （恶劣天气）时，FiLM 满幅调制。

代码改动范围（约 12 行，3 个文件）：

- `orion_head.py`: 传递 `uncertainty_score` 至 `transformer` (当前仅传 `uncertainty_emb`)
- `petr_transformers.py`: FiLM L1 接收 `uncertainty_score`, 实现 Score-Gated 公式
- `orion.py`: FiLM L2 同步修改, 接收从 `orion_head` 返回的新参数

5.1.2 信号有效性验证 (Phase 0, 无 GPU 需求)

在开始 BEV 不确定性热力图工作前, 先验证 image quality metrics 的有效性: 对每帧图像计算三类 per-patch 质量指标——Laplacian variance (边缘清晰度)、梯度幅值 (纹理丰富度)、局部对比度 (Local Contrast, 对雾天对比度下降最敏感), 验证恶劣天气帧的质量指标均值显著低于正常天气帧 ($p < 0.01$)。

5.2 第二阶段: BEV 不确定性热力图 (核心新贡献, 2–4 周)

5.2.1 核心思路

当前 FiLM 方案的空间盲目性源于将 patch 信息压缩为全局向量。受 BEV 感知研究启发, 我们提出将 patch 级感知质量通过 QT-Former 的 cross-attention 权重传播至 BEV 空间, 构建 **BEV 不确定性热力图**, 并将其作为轨迹模式选择的空间代价。

5.2.2 计算流程（零额外参数）

```

Step 1: per-patch quality (从原始图像计算, 无需学习)
    patch_quality[j] = f(Laplacian_var[j], grad_mag[j], contrast[j])

Step 2: BEV uncertainty map (通过 QT-Former attention 传播)
    attn_weight[i,j] = QT-Former cross-attention (hook 读取, flash_attn=
        False)
    bev_uncertainty[i] = sum_j attn_weight[i,j] * (1 - patch_quality[j])
    # 注: BEV query 为 600 main + 300 propagated = 900 个 learned
        embedding
    # reference_points 为 nn.Embedding(600,3) + nn.Embedding(300,3), 非规
        则网格

Step 3: per-mode uncertainty cost (k-NN 空间插值, k=5)
    ref_xy = reference_points[:, :2] * 102.4 - 51.2    # learned -> 物理坐
        标
    uncertainty_cost[m] = mean_t knn_interp(bev_unc, ref_xy, waypoint[m,t
        ], k=5)

Step 4: adjusted mode selection (仅需学 1 个标量 lambda)
    # poses_cls 为 sigmoid scores (非 softmax logits), 采用乘法门控
    adjusted_score = poses_cls * (1 - lambda * uq_score *
        uncertainty_cost)

```

图 2: BEV 不确定性代价计算流程（修正版）。BEV query 为 learned embedding 而非规则网格，采用 k-NN 空间插值替代双线性采样；poses_cls 为 sigmoid scores，采用乘法门控替代 logit 减法。 λ 为唯一训练参数。

关键优势：（1）不需要深度估计或 camera-to-BEV 几何投影；（2）计算 BEV uncertainty map 不需要 LLM 参与，仅需 EVAViT 和 QT-Former（约 0.73GB 显存），可在 16GB 本地设备上完整运行；（3） λ 训练可利用离线缓存的特征数据，与 ORION 推理完全解耦。

关键修正（基于 Phase -1 验证）：（1）BEV query 为 600 main + 300 propagated 个 learned embedding（nn.Embedding，初始化 uniform(0,1)，训练后学习），并非 30×30 规则网格，因此双线性采样不可行，改用基于 reference_points 的 k-NN 空间插值（k=5）；（2）poses_cls 使用 sigmoid focal loss 训练（ $\gamma = 2, \alpha = 0.25$ ），输出为独立 sigmoid scores 而非 softmax 概率，mode 选择方式为 $\text{argmax}(\text{poses_cls})$ ——因此不应在 logit 空间做减法（sigmoid 极端值对减法不敏感），改用乘法门控：adjusted_score =

$\text{poses_cls} \cdot (1 - \lambda \cdot s \cdot c_m)$; (3) Flash Attention 在所有 5 个 transformer 组件中默认开启, 阻断 attention weights 提取——缓解方案为提取时临时覆盖 `flash_attn=False`, 推理速度约降 2× 但仅影响缓存提取阶段。

5.2.3 lambda 训练目标

λ 为单一标量参数, 训练方式有两种选择: (1) **网格搜索** (首选): $\lambda \in \{0.1, 0.3, 0.5, 0.7, 1.0\}$, 直接优化离线缓存数据上的 mode 选择命中率 (选中 GT 最近 mode 的概率), 计算量极小 (CPU 秒级); (2) **可微训练**: 采用 pairwise margin ranking loss 替代 Spearman rank correlation (`torch.argsort` 无梯度), 对每对 mode (m_i, m_j) , 若 m_i 更安全则鼓励 $\text{adjusted_score}(m_i) > \text{adjusted_score}(m_j)$ 。

$$\mathcal{L}_\lambda = \sum_{m_i \succ m_j} \max(0, \text{margin} - (\hat{s}_{m_i} - \hat{s}_{m_j})), \quad \hat{s}_m = \text{poses_cls}_m \cdot (1 - \lambda \cdot s \cdot c_m) \quad (6)$$

其中安全排序基于各模式与 GT 的 L2 距离构造。注意: 原计划中使用的 Spearman ρ_s 不可微 (依赖 `argsort`), 已替换为等价的 pairwise ranking formulation。

5.3 第三阶段: 完整消融实验 (需申请服务器)

5.3.1 消融实验矩阵

表 9: FiLM 与 BEV 代价消融矩阵

组别	配置	Score-Gated FiLM	BEV Cost	说明
A	Baseline	—	—	纯 ORION, 参考基线
B	FiLM-v3	× (有 bug)	—	展示问题, 历史对照
C	Score-Gated FiLM	✓	—	修复 Normal 退化
D	BEV Cost only	—	✓ (空间)	验证空间信息独立贡献
E	Full (C+D)	✓	✓ (空间)	完整方案
F	Global Score Penalty	—	✓ (全局)	关键对照: D vs F 证明空间
G	C+F	✓	✓ (全局)	E vs G 证明空间 BEV 优于全

F 组和 G 组是关键对照: F 组将 $\lambda \cdot s$ (全局标量惩罚, 不含 BEV 地图) 作为所有 mode 的均匀惩罚。D vs F 直接量化空间不确定性信息在无 FiLM 时的独立贡献; E vs G 测试当 FiLM 已存在时, 空间 BEV cost 是否仍优于全局标量——若 E 显著优于 G, 则空间化是有价值的新贡献; 否则应进一步探索 per-BEV-query 细粒度调制。

5.3.2 UQ 组件消融

表 10: UQ 组件消融实验设计

消融	配置文件	说明
Full model	uq_train.yaml	完整 UQEstimator
w/o stat_features	uq_ablation_no_stat.yaml	去掉 5 维统计特征
w/o decoder	uq_ablation_no_decoder.yaml	mean pool 替代 Transformer
w/o ranking loss	uq_ablation_no_ranking.yaml	仅 MSE + calibration
w/o calibration	uq_ablation_no_cal.yaml	仅 MSE + ranking

5.4 长期目标

1. 完成完整消融实验后投稿论文（目标会议待定）
2. 探索 Spatial FiLM 方向（per-BEV-query 独立调制，作为 BEV Cost 的补充或替代）
3. 扩展到更多 OOD 类型（传感器部分遮挡、镜头污损等）

6 资源需求

6.1 计算资源

表 11: 各阶段计算资源需求（本地可完成的任务已标注）

任务	硬件	显存	预估时间	是否需申请
特征提取（已完成）	1× A100	~40GB	~12h	已完成
UQ 训练（已完成）	1× A100	~5GB	~100min	已完成
Phase 0: 信号验证	CPU	0	<1h	本地
Phase 1: BEV 特征提取	消费级 16GB	~1GB	~4h	本地
λ 训练	CPU	0	<0.5h	本地
Score-Gated FiLM 重训	1× A100	~50GB	~24h	需申请
开环评估（6 组）	1× A100	~40GB	~12h	需申请
闭环评估（100 场景 × 4 组）	1× A100	~40GB	~60h	需申请
UQ 消融（4 组）	1× A100	~5GB	~7h	需申请
待申请总 GPU 时间			~103h	

本地设备说明：现有设备为 16GB 显存。ORION 完整推理（含 LLaMA-7B VLM）需 FP16 约 18GB，超出限制；但 BEV 不确定性热力图仅需 EVAViT + QT-Former（约 0.73GB），可在本地完整运行。FiLM 重训若使用 INT8 量化约需 13GB，本地可尝试但存在显存紧张风险，建议在服务器上完成。

6.2 存储资源

表 12: 数据资产存储需求

数据	大小	说明
Bench2Drive 数据集	407 GB	原始数据（已就位）
ORION 模型 + LLM 权重	~50 GB	已就位
预提取 patch tokens	235 GB	已就位
Checkpoints + 结果	~1 GB	持续增长
总计	~693 GB	

6.3 软件环境

- Python 3.11.5, PyTorch 2.1.0, CUDA 11.8
- 使用 uv 管理虚拟环境（.venv/）
- ORION 原始依赖 + UQ 扩展依赖（requirements_uq.txt）

7 可行性分析

7.1 技术可行性

技术可行性评估：

1. **UQ 估计已验证：** AUROC=0.954 远超 0.7 目标，Spearman $\rho=0.97$ ，天气排序完全正确。UQ estimation 部分技术路线已经走通。
2. **FiLM 注入机制已验证：** 恶劣天气碰撞率降低 23%，证明 FiLM 调制确实能改变模型行为。
3. **Score-Gated 方案改动量小：** 修改 3 个文件约 12 行代码 + 重训 FiLM，技术风险低。
4. **消融实验框架已就绪：** 配置文件、训练/评估脚本、可视化工具全部就位。

7.2 风险评估

表 13: 风险评估矩阵

风险	概率	影响	缓解措施
Score-Gated FiLM 未能完全解决 Normal 退化	极低	高	Phase -1 确认: UQ score 高度双峰, Normal 中位数 ≈ 0 , score=0 时 FiLM 严格恒等
BEV 热力图过于平滑 (QT-Former attention 非局域性)	中	中	优先用最后一层 attention; 若仍平滑则改用 gradient-weighted attention (类 Grad-CAM)
D/F/G 组无显著差异 (空间性贡献存疑)	中	高	转向 per-BEV-query Spatial FiLM 方案; BEV Cost 作为辅助验证
BEV————query 非规则网格, 双线性采样不可用	—	—	Phase -1 已发现并修正: 改用 k-NN 插值
Plan————anchor 空间覆盖不足	—	—	Phase -1 已排除: 88.9% pair IoU < 0.5
Flash Attention 阻断 attn_weights 提取	已确认	低	提取时 flash_attn=False, 速度降 2 $\times$ 但仅缓存阶段
碰撞改善幅度不够显著	中	高	扩大评估场景数 (100+); 补充 Bench2Drive 高危场景子集分析
消融某组件贡献不显著	中	低	如实报告, 可作为“轻量简化版”的卖点

7.3 创新点与论文贡献

- 发现: 端到端 VLM 驾驶在恶劣天气下碰撞率放大 161 $\times$, 但开环 L2 指标无法反映; L2 精度与安全性是两个正交维度
- 方法 (第一层): 轻量 UQ 估计器 + Score-Gated FiLM, 通过感知不确定性对 QT-Former 和 VAE 实施条件调制, 零主干微调, 参数增量仅 4.45M

3. **方法（第二层，新贡献）**: 将 per-patch 图像质量通过 QT-Former cross-attention 传播为 BEV 不确定性热力图，直接约束轨迹模式选择，首次实现感知可靠性的空间感知规划
4. **定位**: 轻量侧信道注入设计（在冻结层激活值上施加 FiLM 调制），适用于任意冻结的端到端驾驶模型，无需重训骨干网络
5. **分析**: 系统消融实验（UQ 组件 / FiLM 层级 / 全局 vs 空间不确定性）揭示各模块贡献

8 时间规划

表 14: 后续工作时间规划（括号内为所需计算资源）

时间	任务	交付物
第 1 周	Phase 0: 信号验证 + Score-Gated 代码实现（本地）	验证图 + 代码
第 1-2 周	BEV 不确定性热力图计算与可视化（本地）	热力图对比图（论文图）
第 2 周	λ 训练与 mode cost 验证（本地）	λ checkpoint
第 2-3 周	Score-Gated FiLM 重训 + 开环评估（A100）	更新版表 7
第 3 周	UQ 消融（4 组）+ FiLM 层级消融（A100）	消融对比表
第 3-4 周	完整 7 组闭环评估（A100 + CARLA, 100 场景）	主要实验表
第 4-5 周	论文 Method + Experiments 初稿	草稿
第 5-6 周	Introduction + Related Work + 图表	完整初稿
第 6-7 周	审阅修改 + 定稿	可投稿版本

9 总结

UQ-ORION 项目第一阶段已完成核心验证：UQEstimator 在恶劣天气检测上达到 AUROC=0.954，FiLM 碰撞感知训练在恶劣天气场景降低了 23% 的碰撞率。当前主要问题是 FiLM 对正常场景的非预期干扰（ADE +116%），根因已明确为 FiLM 调制的全局性与 LayerNorm 范数崩塌。

Phase -1 可行性验证（5 项中 4 项已完成）发现并修正了若干关键计划假设：BEV query 为 600+300 个 learned embedding（非 30×30 网格），须用 k-NN 替代双线性采样；poses_cls 为 sigmoid scores（非 softmax logits），须用乘法门控替代 logit 减法；同时确认了 plan anchor 空间多样性充分（88.9% pair IoU < 0.5）、UQ score 高度双峰（Score-Gated FiLM 可行）、Flash Attention 有明确缓解方案。

第二阶段以此为切入点，提出修正后的 BEV 不确定性热力图方案，将感知可靠性空间化，直接指导轨迹模式选择。该方案的核心计算链路（EVAViT + QT-Former + 图像统计量）不依赖 LLM，可在现有 16GB 本地设备上完整运行。消融实验扩展至 7 组（新增 G 组：Score-Gated FiLM + Global Penalty），以更严格地验证空间 BEV cost 的独立贡献。需申请 A100 资源的部分（FiLM 重训、大规模闭环评估）预计总 GPU 时间约 103 小时。预计 6-7 周内可完成论文初稿。

结论可信度汇总

表 15: 关键结论可信度评估

结论	证据	可信度
UQ score 能区分 Normal vs Adverse 天气	AUROC=0.954, Gap=0.870	高
恶劣天气碰撞率显著高于正常天气	161× 差距, 50 场景回放对比	高
FiLM 调制降低了回放碰撞率 21%	50 场景, Baseline vs FiLM v3	中 (回放式, 非真实闭环)
FiLM 调制导致 ADE 退化 +80%	50 场景, 含 Normal +116%	高
Normal ADE 退化由 LayerNorm 引起	代码分析 + 理论推导	中 (未实验验证)
Score-Gated FiLM 能修复 Normal ADE	理论推导 (score=0 时恒等)	低 (checkpoint 未重训)
BEV IPM 能区分场景感知质量	2 场景, $\Delta = +0.139$	中 (样本量小)