

面向端到端自动驾驶的视觉骨干不确定性感知规划

中期进展报告

2026 年 6 月

摘要

本报告总结开题以来围绕 ORION 端到端自动驾驶模型开展的不确定性量化 (Uncertainty Quantification, UQ) 研究进展。0521 阶段的结果表明, 恶劣天气下原始 ORION 的碰撞风险显著上升, 而传统 L2 轨迹误差不能充分反映该风险; 同时, 早期手工 UQ 估计器和后端 FiLM 调制虽然可以改变规划行为, 但存在“伪标签人为设定”和“绕过大模型直接改规划输出”的说服力问题。

针对上述问题, 本阶段将研究重点调整为: 从冻结 EVAViT 视觉骨干中提取基于特征密度的 UQ 分数与表征向量, 并将不确定性作为进入大模型前的视觉证据信号, 而不是直接修改轨迹解码器输出。实验结果显示: 密度不确定性估计在正常/恶劣视觉条件区分上取得 AUROC 0.799、AUPRC 0.951; 显式 UQ 词元能被语言模型读取, 但在缺少规划监督时不能自然改善轨迹; 大模型前视觉适配器在单相机丢失的路线均衡评估中取得平均 ADE 19.3% 的改善, 并且正确 UQ 相比打乱 UQ 仍有 5.3% 的额外收益。当前主要卡点是路线级稳定性与正常输入 FDE 轻微退化, 后续将围绕路线均衡训练、正常输入保持损失和更细粒度分层评估推进。

目录

1 研究背景与问题定义	3
1.1 研究对象	3
1.2 0521 阶段发现	3
2 方法演进	3
2.1 从手工 UQ 估计器到密度不确定性估计	3
2.2 三条注入路线	5

3	实验设置	5
3.1	数据与视觉特征	5
3.2	配对扰动监督	5
3.3	大模型前视觉适配器	5
4	实验结果	6
4.1	密度不确定性估计监测能力	6
4.2	显式 UQ 词元：语义可读但规划负结果	6
4.3	大模型前视觉适配器：路线均衡受损输入评估	7
4.4	高低 UQ 分层	8
4.5	正常输入安全性检查	9
5	当前进展评估	10
5.1	相对开题目标的完成情况	10
5.2	已完成产物	10
6	问题、风险与下一步计划	11
6.1	当前卡点	11
6.2	下一阶段计划	11
7	总结	11

1 研究背景与问题定义

1.1 研究对象

本课题基于 ORION 视觉语言端到端自动驾驶框架 [1]。ORION 的主流程为：

多视角图像 $\rightarrow$ EVAViT $\rightarrow$ QT-Former $\rightarrow$ Qwen 大模型
 $\rightarrow$ 规划词元 $\rightarrow$ 轨迹解码器。

该类基于视觉语言模型的规划器优势是能够将视觉理解、语言推理和轨迹规划结合起来；但在雨、雾、夜间、相机受损等视觉质量下降场景下，模型缺少显式的自我可靠性估计，容易在感知不可靠时仍输出过度自信的规划。

1.2 0521 阶段发现

0521 报告的核心结论可以概括为三点。相关实验基于 Bench2Drive 验证集 [2]，并复用 ORION 中冻结的 EVAViT 视觉骨干特征 [3, 4]。

1. **安全风险与 L2 不一致。**在 Bench2Drive 验证集上，恶劣天气的碰撞风险显著高于正常天气，但 L2 轨迹误差不一定更高。这说明仅依赖开环 L2 难以定位安全风险。
2. **早期 UQ 估计器能监测视觉退化。**基于 EVAViT 词元统计特征的手工 UQ 估计器可以区分正常/恶劣场景。
3. **直接后端调制存在叙事风险。**将 UQ 分数直接用于 L2/解码器 FiLM 调制容易被理解为“人为控制轨迹解码器”，没有充分体现大模型自身利用不确定性的能力。

中期阶段的核心调整

本阶段不再将“直接调制轨迹输出”作为主线，而是将问题改写为：**能否从冻结视觉骨干中得到有理论依据的不确定性表示，并把它作为进入大模型前的视觉证据调节信号，让大模型仍然承担最终规划决策？**

2 方法演进

2.1 从手工 UQ 估计器到密度不确定性估计

原始 UQ 估计器的接口是：

EVAViT 特征 $\mapsto$ (不确定性分数, 不确定性表征向量)。

其中分数用于打标签或门控，表征向量用于下游调制。问题在于，早期分数依赖人为构造的伪标签，理论依据较弱。

本阶段将 UQ 估计器替换为基于正常视觉特征流形的密度不确定性估计。具体做法是：在正常视觉样本上建立 EVAViT 描述子的密度分布；测试样本若偏离正常特征流形，则不确定性更高。该思路与 Mahalanobis 距离分布外检测 [5]、Deep k-NN 不确定性 [6] 以及分布外检测基线 [7] 一致。这样得到的分数可以解释为分布外程度，表征向量则由有效密度方向投影得到，并扩展到兼容旧接口的 256 维表示。




图 1: 从 0521 报告的手工 UQ 估计器/后端 FiLM，到当前密度不确定性估计/大模型前视觉适配器的方法演进。

表 1: 密度不确定性估计与原 UQ 估计器的接口对应

输出	原方案	当前方案
分数	手工伪标签回归	Mahalanobis 距离/密度距离标量
表征向量	UQ 估计器中间特征	PCA 密度方向，兼容 256 维接口
用途	FiLM 门控/调制	大模型前的视觉证据条件化、分层评估

2.2 三条注入路线

表 2: 本阶段验证过的 UQ 注入路线

路线	核心思路	当前结论	状态
密度不确定性估计监测	用 EVAViT 词元分布密度估计不确定性	理论依据强于手工 UQ 估计器, 可保留为基础模块	保留
显式 UQ 词元	将分数与表征向量投影成大模型输入词元	大模型能读出可靠性语义, 但规划不自然改善	暂停扩大
大模型前视觉适配器	用 UQ 条件化视觉查询向量, 再交给大模型决策	路线均衡受损输入评估平均有效	主线

3 实验设置

3.1 数据与视觉特征

实验使用 Bench2Drive 验证集 [2], 共 12,806 个样本。前期已在服务器上完成 ORION EVAViT 特征提取, 缓存为每样本 $[6, 1600, 1024]$ 的 float16 图像块特征。正常/恶劣的基础划分沿用天气 ID 规则: Weather ID 0-3 为正常, 其余天气条件为恶劣。

3.2 配对抗动监督

为了避免人为规定“高不确定性就应该刹车”, 本阶段采用配对抗动的监督思想: 对同一场景构造正常输入与受损输入, 使几何和专家轨迹保持一致, 仅破坏视觉输入。训练目标不是让模型输出手工保守轨迹, 而是让:

$$d(\text{受损} + \text{正确 UQ}, \text{正常参考}) < d(\text{受损} + \text{打乱 UQ}, \text{正常参考}).$$

扰动审计结果表明, 单相机丢失强度 1 能稳定提升密度不确定性分数, 且语义清楚, 因此当前用它作为主要受损视觉设置。

3.3 大模型前视觉适配器

显式 UQ 词元路线失败后, 主线改为大模型前视觉适配器。其思想与 FiLM 条件调制 [8] 和参数高效适配 [9] 相关, 但注入位置限定在大模型前视觉查询向量, 避免直接修改轨迹解码器:

$$q' = q + s_{\text{UQ}} \cdot \text{up}(\text{GELU}(\text{down}(\text{LN}(q)))).$$

其中 q 为进入大模型的视觉查询向量， s_{UQ} 为密度不确定性分数。适配器采用零初始化，因此初始状态严格等价于恒等，不会在训练前破坏 ORION 原有输出。该设计不直接接触 VAE 或轨迹解码器，因此比 L2 FiLM 更符合“让大模型基于可靠性条件化后的视觉证据做决策”的研究主张。

4 实验结果

4.1 密度不确定性估计监测能力




图 2: 密度不确定性估计对视觉条件变化具有可观测分离度。

表 3: 密度不确定性估计监测结果

指标	结果	说明
AUROC	0.799	区分留出正常/恶劣视觉条件
AUPRC	0.951	恶劣占比较高时更稳定
路线-自助法 AUROC 95% CI	0.675–0.915	路线数量有限导致置信区间较宽
有效表征维度	16	实际密度方向维度
兼容表征维度	256	保持旧 UQ 估计器接口兼容

4.2 显式 UQ 词元：语义可读但规划负结果

R2d 可靠性问答显示，大模型可以从连续 UQ 词元中读出可靠性语义：正确 UQ 的解析率/准确率为 0.97/0.90，打乱 UQ 为 0.99/0.96；无注入/零值注入设置下没有可解析可靠性描述。这说明 UQ 词元不是无意义噪声。

但是在规划预实验中，显式词元并未带来轨迹改善。50 帧一致性预实验中，受损输入的 ADE 分别为无注入 0.1910、打乱 UQ 0.2147、正确 UQ 0.2447；反事实排序预实验中正确 UQ 也未优于打乱 UQ。因此当前判断是：**语言通道能读取 UQ，但没有规划监督时，可靠性语义不会自然转化为轨迹变化。**


4.3 大模型前视觉适配器：路线均衡受损输入评估

使用 pilot100 适配器，在校准集上做路线均衡评估：10 条路线，每条抽 50 个候选帧，其中 35 个有效规划帧，共 350 个有效样本。输入采用单相机丢失强度 1，比较无注入、零值注入、打乱 UQ 和正确 UQ 四种干预。


表 4: 路线均衡受损输入评估整体结果

UQ 模式	ADE	FDE	数量
无注入	1.4429	2.5210	350
零值注入	1.4429	2.5210	350
打乱 UQ	1.2286	2.1969	350
正确 UQ	1.1641	2.0955	350

相对无注入，正确 UQ 的 ADE 改善为 19.3%；相对打乱 UQ，正确 UQ 仍有 5.3% 的额外改善。这表明适配器的收益并非完全来自随机扰动或额外参数，而与正确 UQ 条件信号有关。



(a) 逐路线 ADE



(b) 正确 UQ 相对无注入的改善

图 3: 路线均衡评估显示平均收益成立，但路线级仍有波动。

表 5: 逐路线 ADE 摘要

路线	无注入	打乱	正确
VanillaSignalizedTurnRedLight	2.174	1.049	0.754
OppositeVehicleRunningRedLight	0.689	0.504	0.436
HighwayExit	0.747	0.606	0.533
VehicleTurningRoute	0.728	0.601	0.555
BlockedIntersection	2.366	1.956	1.873
SignalizedJunctionLeftTurn	0.886	0.814	0.829
YieldToEmergencyVehicle	3.477	3.496	3.496

4.4 高低 UQ 分层

为了检验“高不确定性样本是否收益更明显”，进一步保存逐样本规划记录，并按密度不确定性分数中位数划分高 UQ/低 UQ。

表 6: 按 UQ 分数中位数分层的 ADE

分组	数量	无注入	打乱	正确	正确 UQ 相比打乱 UQ
高 UQ	192	1.673	1.526	1.502	+1.6%
低 UQ	158	1.262	1.089	1.052	+3.4%




图 4: 高低 UQ 分层结果。

该结果说明正确 UQ 在两组中都优于打乱 UQ，但收益并没有集中在高 UQ，低 UQ 组的相对改善反而更大。因此当前不能声称“高 UQ 场景收益更明显”。更稳妥的结论是：密度不确定性估计已经能作为有效条件信号改善平均规划，但分数标量与规划收益强度之间的单调关系尚未建立。

4.5 正常输入安全性检查

同样的路线均衡评估也在正常输入上进行，用于确认适配器是否破坏正常输入。

表 7: 正常输入安全性检查

模式	ADE	FDE	ADE 变化	FDE 变化
无注入	0.8884	1.3707	+0.0%	+0.0%
打乱 UQ	0.9008	1.4265	+1.4%	+4.1%
正确 UQ	0.8971	1.4248	+1.0%	+4.0%




图 5: 正常输入安全性: ADE 基本安全, FDE 有轻微退化。

结论是: 正常输入 ADE 退化约 1.0%, 低于 3% 阈值; 但正常输入 FDE 退化约 4.0%, 略高于严格阈值。下一轮训练需要显式加入正常输入保持损失或恒等正则。

5 当前进展评估

5.1 相对开题目标的完成情况

表 8: 开题目标与当前进展

目标	当前进展	评价
视觉不确定性监测	完成 EVAViT 特征提取、密度不确定性估计、正常/恶劣检测	已形成可写入中期报告的结果
不确定性进入规划链路	验证显式词元与大模型前视觉适配器两条路线	主线已明确，显式词元作为负结果诊断
证明 UQ 被模型使用	正确 UQ 相比打乱 UQ 对照显示正确 UQ 有额外收益	初步成立，但仍需更大规模训练
保证正常场景安全	正常输入 ADE 基本安全，FDE 略退化	需作为下一阶段重点修复
可视化展示	已生成路线级图和 BEV 轨迹 GIF	可用于中期汇报

5.2 已完成产物

- 完成 12,806 个 Bench2Drive 样本的 EVAViT 特征缓存。
- 实现密度不确定性估计、UQ 词元投影器、扰动流程、视觉适配器。
- 完成显式 UQ 词元可靠性问答与规划预实验。
- 完成大模型前视觉适配器的配对扰动预实验、路线均衡评估、高低 UQ 分层和正常输入安全性检查。
- 完成若干路线的 BEV 轨迹 GIF，用于展示适配器对轨迹行为的影响。

6 问题、风险与下一步计划

6.1 当前卡点

主要问题

1. 路线级稳定性不足。正确 UQ 平均优于打乱 UQ, 但 YieldToEmergencyVehicle 等路线没有改善。

2. UQ 分数与规划收益不单调。高 UQ 组没有比低 UQ 组表现出更强收益, 说明当前分数还不能直接解释为规划收益。

3. 正常输入 FDE 轻微退化。正常输入上 FDE 退化约 4.0%, 需要正常输入保持损失。

4. 实验规模仍偏预实验。当前适配器训练规模约 100 步预实验, 尚未完成 500-1000 配对样本的路线均衡训练。

6.2 下一阶段计划

表 9: 下一阶段实验计划

任务	内容	预计耗时	通过标准
路线均衡训练	500-1000 配对样本, 仅训练适配器, LoRA 学习率为 0	0.5-1 天	正确 UQ 稳定优于打乱 UQ
正常输入保持	加入正常输入恒等/保持损失	0.5 天	正常输入 ADE/FDE 退化 < 3%
表征向量条件	将有效密度表征向量与分数同时注入适配器	0.5-1 天	高 UQ 分层更可解释
路线/天气分层	按路线类型、天气 ID、扰动强度分层	0.5 天	找出收益/失败边界
中期材料固化	更新报告、PPT、GIF 与考核表内容	已完成本版	口径一致、可汇报

7 总结

本阶段的核心进展不是简单扩大 0521 的后端 FiLM, 而是完成了一次关键路线修正: 从“用 UQ 直接改规划输出”转向“用有理论依据的视觉骨干不确定性条件化大模型

前的视觉证据”。实验上，密度不确定性估计提供了比手工 UQ 估计器更强的理论依据；显式 UQ 词元的负结果说明仅让大模型读懂可靠性还不够；大模型前视觉适配器在路线均衡受损输入评估上取得平均收益，并通过正确/打乱 UQ 对照初步证明了 UQ 条件信号的有效性。后续若进一步引入概率不确定性建模，也可参考贝叶斯深度学习与数据不确定性/模型不确定性的经典框架 [10, 11]。

当前结论应保持克制：方法已经显示可行性，但还没有达到稳定泛化。中期报告中可以将其表述为**机制验证已完成，主线方案已收敛，下一阶段进入路线均衡扩展训练与安全性约束**。

参考文献

- [1] Haoyu Fu, Diankun Zhang, Zongchuang Zhao, Jianfeng Cui, Dingkang Liang, Chong Zhang, Dingyuan Zhang, Hongwei Xie, Bing Wang, and Xiang Bai. ORION: A Holistic End-to-End Autonomous Driving Framework by Vision-Language Instructed Action Generation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2025.
- [2] Xiaosong Jia, Zhenjie Yang, Qifeng Li, Zhiyuan Zhang, and Junchi Yan. Bench2Drive: Towards Multi-Ability Benchmarking of Closed-Loop End-to-End Autonomous Driving. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2024.
- [3] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. EVA: Exploring the Limits of Masked Visual Representation Learning at Scale. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023.
- [4] Yuxin Fang, Quan Sun, Xinggang Wang, Tiejun Huang, Xinlong Wang, and Yue Cao. EVA-02: A Visual Representation for Neon Genesis. *arXiv preprint arXiv:2303.11331*, 2023.
- [5] Kimin Lee, Kibok Lee, Honglak Lee, and Jinwoo Shin. A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [6] Nicolas Papernot and Patrick McDaniel. Deep k-Nearest Neighbors: Towards Confident, Interpretable and Robust Deep Learning. *arXiv preprint arXiv:1803.04765*, 2018.

- [7] Dan Hendrycks and Kevin Gimpel. A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks. In *International Conference on Learning Representations (ICLR)*, 2017.
- [8] Ethan Perez, Florian Strub, Harm de Vries, Vincent Dumoulin, and Aaron Courville. FiLM: Visual Reasoning with a General Conditioning Layer. In *AAAI Conference on Artificial Intelligence*, 2018.
- [9] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *International Conference on Learning Representations (ICLR)*, 2022.
- [10] Yarin Gal and Zoubin Ghahramani. Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning. In *International Conference on Machine Learning (ICML)*, 2016.
- [11] Alex Kendall and Yarin Gal. What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision? In *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.