

UQ-ORION: 面向恶劣天气的不确定性感知端到端自动驾驶安全扩展

研究进展报告

2026 年 4 月 1 日

摘要

本报告总结 UQ-ORION 项目的当前进展。该项目在 ORION (ICCV 2025) 端到端自动驾驶框架的基础上,通过轻量不确定性量化(UQ)模块和 FiLM 条件调制机制,提升模型在恶劣天气场景(雨、雾、夜间)下的安全性。

截至目前,我们已完成 UQEstimator 训练(AUROC=0.954)、FiLM 双层注入、碰撞感知训练、以及 50 场景闭环评估。实验表明恶劣天气下碰撞率降低 21%–23%,但存在正常场景轨迹退化问题(ADE +116%),已定位根因(FiLM 调制的空间盲目性与 LayerNorm 范数崩塌)。

在此基础上,本报告提出第二阶段改进方向:以 BEV 不确定性热力图替代全局调制,将感知不确定性空间化,使规划器能够主动规避感知可靠性低的区域。该方向不依赖语言模型(LLM)的前向传播即可计算核心特征,具备在 16GB 消费级 GPU 上推进的条件。本报告对完整技术路线、各阶段资源需求与可行性进行系统分析。

目录

1 研究背景与动机	2
1.1 问题定义	2
1.2 研究目标	2
2 技术方案	3
2.1 整体架构	3
2.2 UQEstimator 模型	3
2.3 FiLM 双层注入	4

2.4	当前 FiLM 方案的根本局限	4
2.5	损失函数设计	4
2.6	参数预算	5
3	当前进展	5
3.1	完成阶段概览	5
3.2	实验结果	6
3.2.1	UQ Score 分离度 (v3, weather-based 分类)	6
3.2.2	闭环评估结果 (50 场景, 修复 init_weights 后)	6
3.2.3	Baseline 规划指标分析	7
4	遇到的问题与解决方案	7
4.1	问题 1: 伪标签分类不一致 (已解决)	7
4.2	问题 2: init_weights 覆盖 FiLM Identity Init (已修复)	8
4.3	问题 3: Normal 场景 ADE 严重退化 (待解决)	8
4.4	问题 4: FiLM 的“保守捷径”现象	8
5	后续工作规划	9
5.1	第一阶段: 修复现有方案 (1-2 周, 本地 16GB 可完成)	9
5.1.1	Score-Gated FiLM 实现与重训	9
5.1.2	信号有效性验证 (Phase 0, 无 GPU 需求)	9
5.2	第二阶段: BEV 不确定性热力图 (核心新贡献, 2-4 周)	9
5.2.1	核心思路	9
5.2.2	计算流程 (零额外参数)	10
5.2.3	lambda 训练目标	10
5.3	第三阶段: 完整消融实验 (需申请服务器)	11
5.3.1	消融实验矩阵	11
5.3.2	UQ 组件消融	11
5.4	长期目标	11
6	资源需求	12
6.1	计算资源	12
6.2	存储资源	12
6.3	软件环境	13
7	可行性分析	13
7.1	技术可行性	13
7.2	风险评估	14
7.3	创新点与论文贡献	14

8 时间规划	15
9 总结	15

1 研究背景与动机

1.1 问题定义

ORION 是一个基于 VLM (Vision-Language Model) 的端到端自动驾驶框架，在标准场景下表现优秀。其核心流程为：

Vision Encoder → QT-Former → VLM → Planning Token → VAE → 轨迹

然而，VLM-based planner 存在一个关键缺陷：**在恶劣天气（雨、雾、夜间）等 OOD 场景下过度自信**，无法感知自身感知质量的下降，从而做出激进的轨迹决策。

通过对 Bench2Drive 验证集（12,806 个样本）的分析，我们发现了一个令人警醒的统计事实：

核心发现：恶劣天气碰撞率放大效应

- 恶劣天气碰撞率是正常天气的 **161 倍** (1.61% vs 0.01%)
- 但恶劣天气的 L2 轨迹误差反而**低于**正常天气 (1.78m vs 2.38m)
- 模型「看起来精度不错」但实际碰撞风险剧增

这一发现揭示了传统开环 L2 评估指标的局限性——轨迹精度与安全性是两个不同维度的概念。

1.2 研究目标

在不微调 ORION 主干（~1B 参数，36GB 模型文件）的前提下，设计一个轻量即插即用的不确定性感知安全扩展方案：

1. **量化感知不确定性**：训练轻量 UQ 估计器，从视觉 token 提取每帧的不确定性分数与嵌入
2. **空间化不确定性**：将不确定性从全局标量升维为 BEV 空间热力图，使规划器感知”哪个区域的感知不可靠”
3. **约束轨迹决策**：用不确定性代价约束多模态轨迹模式选择，主动规避感知可靠性低的区域

约束条件：新增参数 < 5M，零主干微调，即插即用（任意冻结的端到端驾驶模型均可适用）。

2 技术方案

2.1 整体架构




图 1: UQ-ORION 整体架构。灰色部分为 ORION 原有冻结模块，蓝色为本项目新增模块。

2.2 UQEstimator 模型

UQEstimator 接收 EVAViT 的 patch tokens 和 5 维统计特征，输出不确定性 score $\in [0, 1]$ 和 256 维 embedding。

模型结构：

- **Patch 投影**：Linear(1024 $\rightarrow$ 256)，降维控制参数量
- **Cross-Attention 池化**：2 层 TransformerDecoder，16 个 learnable queries 通过 cross-attention 自适应关注最相关的 patches
- **统计特征分支**：5 维原始特征 $\rightarrow$ Linear(5 $\rightarrow$ 64) + GELU + LayerNorm
- **融合**：concat [256 + 64] $\rightarrow$ 512 $\rightarrow$ 256
- **输出头**：score_head (Sigmoid $\rightarrow$ [0, 1])，embed_head (LayerNorm $\rightarrow$ FiLM 条件向量)

总参数量: 2,210,817 (2.21M), 远在 5M 预算之内。

2.3 FiLM 双层注入

FiLM (Feature-wise Linear Modulation) 通过 $\text{output} = \gamma \odot \text{input} + \beta$ 实现条件调制:

- **FiLM L1** (QT-Former 层, 0.13M): 调制检测 query, 让下游 LLM 接收到“视野受限”的场景表示
- **FiLM L2** (VAE 层, 2.11M): 调制 ego_feature (规划 token), 将轨迹分布向保守模式偏移

两层 FiLM 均采用 Identity 初始化 ($\gamma = 1, \beta = 0$), 确保新增模块不破坏原有性能。

2.4 当前 FiLM 方案的根本局限

在第一阶段的实验结果中, Normal 场景 ADE 退化 +116% 揭示了当前方案的两个结构性缺陷:

缺陷一: 空间盲目性。 UQEstimator 通过 mean-pool 将 6×1600 个 patch 的 cross-attention 权重压缩为 256 维全局向量, 空间信息完全丢失。FiLM 对 900 个 BEV query 施加相同调制, 无法区分“前方不确定”与“侧方不确定”。

缺陷二: LayerNorm 范数崩塌。 embed_head 末尾的 LayerNorm 使所有样本的 embedding ℓ_2 -norm 恒定 ($\approx \sqrt{256}$)。因此, FiLM 的调制强度不随 UQ score 变化, Normal 场景 (score ≈ 0) 也受到等幅调制。

这两个缺陷相互叠加, 导致现有 FiLM 方案的本质是“全局风格迁移”而非“空间感知的安全规划”。后续工作针对这两点分别设计修复方案 (见第 5 节)。

2.5 损失函数设计

UQEstimator 训练:

$$\mathcal{L}_{\text{UQ}} = \mathcal{L}_{\text{MSE}} + 0.1 \cdot \mathcal{L}_{\text{cal}} + 0.5 \cdot \mathcal{L}_{\text{rank}} \quad (1)$$

其中 $\mathcal{L}_{\text{cal}}$ 为校准正则项 (惩罚 score 标准差过小), $\mathcal{L}_{\text{rank}}$ 为 pairwise margin ranking loss。

FiLM 碰撞感知训练:

$$\mathcal{L}_{\text{FiLM}} = \mathcal{L}_{\text{plan}} + \lambda_{\text{col}} \cdot \mathcal{L}_{\text{col}} \quad (2)$$

其中碰撞 loss 为 UQ score 加权的 hinge margin loss:

$$\mathcal{L}_{\text{col}} = \mathbb{E} [\text{ReLU}(m - d_{\min}) \cdot s_{\text{UQ}}], \quad m = 4.0\text{m}, \quad \lambda_{\text{col}} = 0.5 \quad (3)$$

2.6 参数预算

表 1: 新增模块参数量

模块	位置	参数量	说明
UQEstimator	独立模块	2,210,817 (2.21M)	Transformer decoder + MLP
FiLM L1 ($\gamma + \beta$)	QT-Former	131,584 (0.13M)	Linear(256 $\rightarrow$ 256) $\times$ 2
FiLM L2 ($\gamma + \beta$)	VAE 前	2,105,344 (2.11M)	Linear(256 $\rightarrow$ 4096) $\times$ 2
合计		4,447,745 (4.45M)	ORION 主干的 0.45%

3 当前进展

3.1 完成阶段概览

表 2: 项目流水线各阶段状态

阶段	内容	状态	关键产出
Stage 0	特征提取 (EVAViT)	完成	12,806 样本, 235GB
Stage 1a	伪标签生成 (v3)	完成	AUROC 0.954
Stage 1b	UQEstimator 训练	完成	Spearman $\rho=0.97$
Stage 2a	开环评估 + UQ hook	完成	12,806 样本全量
Stage 2b	FiLM L1/L2/L1+L2 训练	完成	3 组权重
Stage 3	碰撞感知 FiLM 训练	完成	Col-21%
Stage 4	50 场景闭环评估	完成	含 Baseline 对照
可视化	5 张图 + 18 个 GIF	完成	论文级可视化
下一步	Score-Gated FiLM	待实现	修复 Normal 退化
下一步	UQ 组件消融	待实验	4 组消融对比

3.2 实验结果

3.2.1 UQ Score 分离度 (v3, weather-based 分类)

表 3: UQ Score 分离度指标

指标	Normal	Adverse	Gap	目标
UQ Score 均值	0.023	0.893	0.870	> 0.1 ✓
UQ Score 中位数	0.00008	0.970	0.970	—
AUROC (adverse 检测)	—		0.954	> 0.7 ✓✓

UQ score 在天气维度上的排序完全正确 (表 4), 从 ClearNoon 的接近零到 MidRain-Sunset 的接近 1, 与视觉降质程度高度一致。

表 4: 逐天气类型 UQ Score

天气	分类	UQ Score	语义
ClearNoon	Normal	0.0001	完美感知
ClearSunset	Normal	0.0009	接近完美
CloudyNoon	Normal	0.072	轻微退化
MidRainyNoon	Adverse	0.231	中度退化
HardRainNight	Adverse	0.989	严重退化
MidRainSunset	Adverse	0.997	极端退化

3.2.2 闭环评估结果 (50 场景, 修复 init_weights 后)

表 5: 闭环评估: Baseline vs FiLM v3 (50 场景)

指标	Baseline	FiLM v3	变化
ALL (50) Col@3s	0.66%	0.52%	-21%
ALL ADE@3s	2.46m	4.44m	+80%
Normal (11) Col@3s	0.05%	0.11%	+0.06%
Normal ADE@3s	2.78m	6.00m	+116%
Adverse (39) Col@3s	0.83%	0.64%	-23%
Adverse ADE@3s	2.37m	4.00m	+69%

结果解读

- 恶劣天气碰撞率降低 23% (0.83% $\rightarrow$ 0.64%), 符合预期
- 但正常天气 ADE 从 2.78m 退化至 6.00m (+116%), 这是当前最严重的问题
- 根因已定位: embed_head 的 LayerNorm 导致 FiLM 在 Normal 场景也产生非平凡调制

3.2.3 Baseline 规划指标分析

表 6: Baseline 开环指标 (12,806 样本)

指标	Normal	Adverse	倍数
L2@3s	2.38m	1.78m	0.75 $\times$
Col@1s	0.02%	1.78%	89 $\times$
Col@3s	0.01%	1.61%	161$\times$

4 遇到的问题与解决方案

4.1 问题 1: 伪标签分类不一致 (已解决)

严重性: 高 状态: 已解决

现象: v2 伪标签使用场景类型 (Accident $\rightarrow$ adverse) 分类, 但 eval_openloop 使用天气 ID (Weather 0-3=normal) 分类。2,481/12,806 样本 (19.4%) 分类不一致。
影响: v2 AUROC 0.993 仅在自身标签空间有效, 在 eval_openloop 空间实际仅为 0.601。

解决方案 (v3): 引入 weather-based 分类对齐 eval_openloop, 修正后 AUROC 提升至 **0.954**。

4.2 问题 2: `init_weights` 覆盖 FiLM Identity Init (已修复)

严重性: 高 状态: 已修复

现象: `PETRTemporalTransformer.init_weights()` 对所有 `Linear` 层执行 `xavier_uniform_`, 覆盖了 FiLM 层精心设置的 identity 初始化 ($\gamma = 1, \beta = 0$)。

影响: 未加载训练权重时 FiLM 不是 identity 而是随机调制。早期 10 场景 baseline 数据不可信。

解决方案: 在 `init_weights()` 中用参数 ID 排除 FiLM 层。修复后重跑 50 场景 baseline 获得可信对照数据。

4.3 问题 3: Normal 场景 ADE 严重退化 (待解决)

严重性: 状态: 已定位根因, 待实现修复

现象: Normal 场景 UQ score ≈ 0 (0.0001–0.0015), FiLM 不应有任何调制效果, 但 ADE 从 2.78m $\rightarrow$ 6.00m (+116%)。

根因: `embed_head` 末尾的 `LayerNorm` 使所有样本的 embedding ℓ_2 norm 恒定 ($\approx \sqrt{256} \approx 16$), 无论 UQ score 高低。FiLM 计算 $\gamma = W \cdot \text{emb} + b$ 时, 由于 embedding norm 恒定, Normal 和 Adverse 场景的调制幅度相当。

设计方案: Score-Gated FiLM (见第 ?? 节)。

4.4 问题 4: FiLM 的“保守捷径”现象

严重性: 中 状态: 需第二轮训练解决

现象: 碰撞感知训练使模型全面趋于保守 (Brake MAE +129%, Throttle MAE +74%), 通过“更慢、更停、更让”降低碰撞率, 而非更智能的避障。

影响: ADE 增加 41–80%。部分场景 (CrossingBicycleFlow) 甚至因过度制动引入新碰撞。

解决方向:

1. 引入进度/舒适约束, 抑制无理由降速
2. Score-Gated FiLM 实现选择性调制
3. 对 γ, β 偏离 identity 加正则约束

5 后续工作规划

5.1 第一阶段：修复现有方案（1–2 周，本地 16GB 可完成）

5.1.1 Score-Gated FiLM 实现与重训

解决 LayerNorm 范数崩塌问题，将 UQ score 直接作为调制强度的门控信号：

$$\gamma_{\text{raw}} = W_{\gamma} \cdot \text{emb} + b_{\gamma}, \quad \beta_{\text{raw}} = W_{\beta} \cdot \text{emb} + b_{\beta} \quad (4)$$

$$\gamma = 1 + s \cdot (\gamma_{\text{raw}} - 1), \quad \beta = s \cdot \beta_{\text{raw}} \quad (5)$$

当 $s \rightarrow 0$ （正常场景）时， $\gamma \rightarrow 1, \beta \rightarrow 0$ ，FiLM 退化为恒等变换；当 $s \rightarrow 1$ （恶劣天气）时，FiLM 满幅调制。改动量仅约 6 行代码，需重训 FiLM。

5.1.2 信号有效性验证（Phase 0，无 GPU 需求）

在开始 BEV 不确定性热力图工作前，先验证 image quality metrics 的有效性：对每帧图像计算三类 per-patch 质量指标——Laplacian variance（边缘清晰度）、梯度幅值（纹理丰富度）、局部对比度（Local Contrast，对雾天对比度下降最敏感），验证恶劣天气帧的质量指标均值显著低于正常天气帧（ $p < 0.01$ ）。

5.2 第二阶段：BEV 不确定性热力图（核心新贡献，2–4 周）

5.2.1 核心思路

当前 FiLM 方案的空间盲目性源于将 patch 信息压缩为全局向量。受 BEV 感知研究启发，我们提出将 **patch 级感知质量** 通过 QT-Former 的 cross-attention 权重传播至 BEV 空间，构建 **BEV 不确定性热力图**，并将其作为轨迹模式选择的 **空间代价**。

5.2.2 计算流程（零额外参数）

```

Step 1: per-patch quality (从原始图像计算, 无需学习)
    patch_quality[j] = f(Laplacian_var[j], grad_mag[j], contrast[j])

Step 2: BEV uncertainty map (通过 QT-Former attention 传播)
    attn_weight[i,j] = QT-Former cross-attention (hook 读取)
    bev_uncertainty[i] = sum_j attn_weight[i,j] * (1 - patch_quality[j])
    reshape: [B, 900] -> [B, 30, 30]

Step 3: per-mode uncertainty cost
    uncertainty_cost[m] = mean_t bilinear_sample(bev_uncertainty,
        waypoint[m,t])

Step 4: adjusted mode selection (仅需学 1 个标量 lambda)
    adjusted_logit = cls_logit - lambda * score * uncertainty_cost

```

图 2: BEV 不确定性代价计算流程, 全程无新增可学习参数 (λ 为唯一训练参数)。

关键优势: (1) 不需要深度估计或 camera-to-BEV 几何投影; (2) 计算 BEV uncertainty map 不需要 LLM 参与, 仅需 EVAViT 和 QT-Former (约 0.73GB 显存), 可在 16GB 本地设备上完整运行; (3) λ 训练可利用离线缓存的特征数据, 与 ORION 推理完全解耦。

5.2.3 lambda 训练目标

训练 λ 时采用组合损失, 同时优化碰撞率和 mode 排序质量:

$$\mathcal{L}_\lambda = \alpha \cdot \mathcal{L}_{\text{col}} + (1 - \alpha) \cdot (1 - \rho_s(\text{adjusted_rank}, \text{safety_rank})) \quad (6)$$

其中 ρ_s 为 Spearman 相关系数, safety_rank 基于各模式与 GT 的 L2 距离构造。相比纯碰撞率, Spearman 损失对 mode 排序的优化更稳定, 不受 VAE 离散采样噪声的干扰。

5.3 第三阶段：完整消融实验（需申请服务器）

5.3.1 消融实验矩阵

表 7: FiLM 与 BEV 代价消融矩阵

组别	配置	Score-Gated FiLM	BEV Cost	说明
A	Baseline	—	—	纯 ORION，参考基线
B	FiLM-v3	(有 bug)	—	展示问题，历史对照
C	Score-Gated FiLM	—	—	修复 Normal 退化
D	BEV Cost only	—	(空间)	验证空间信息独立贡献
F	Global Score Penalty	—	(全局)	关键对照：D vs F 证明空间
E	Full (C+D)			完整方案

F 组是关键对照组：F 组将 $\lambda \cdot s$ （全局标量惩罚，不含 BEV 地图）作为所有 mode 的均匀惩罚。D 组与 F 组的差异直接量化了空间不确定性信息对规划质量的独立贡献——若 D 显著优于 F，则空间化是有价值的新贡献；否则应进一步探索 per-BEV-query 细粒度调制。

5.3.2 UQ 组件消融

表 8: UQ 组件消融实验设计

消融	配置文件	说明
Full model	uq_train.yaml	完整 UQEstimator
w/o stat_features	uq_ablation_no_stat.yaml	去掉 5 维统计特征
w/o decoder	uq_ablation_no_decoder.yaml	mean pool 替代 Transformer
w/o ranking loss	uq_ablation_no_ranking.yaml	仅 MSE + calibration
w/o calibration	uq_ablation_no_cal.yaml	仅 MSE + ranking

5.4 长期目标

1. 完成完整消融实验后投稿论文（目标会议待定）
2. 探索 Spatial FiLM 方向（per-BEV-query 独立调制，作为 BEV Cost 的补充或替代）
3. 扩展到更多 OOD 类型（传感器部分遮挡、镜头污损等）

6 资源需求

6.1 计算资源

表 9: 各阶段计算资源需求（本地可完成的任务已标注）

任务	硬件	显存	预估时间	是否需申请
特征提取（已完成）	1× A100	~40GB	~12h	已完成
UQ 训练（已完成）	1× A100	~5GB	~100min	已完成
Phase 0: 信号验证	CPU	0	<1h	本地
Phase 1: BEV 特征提取	消费级 16GB	~1GB	~4h	本地
λ 训练	CPU	0	<0.5h	本地
Score-Gated FiLM 重训	1× A100	~50GB	~24h	需申请
开环评估（6 组）	1× A100	~40GB	~12h	需申请
闭环评估（100 场景 × 4 组）	1× A100	~40GB	~60h	需申请
UQ 消融（4 组）	1× A100	~5GB	~7h	需申请
待申请总 GPU 时间			~103h	

本地设备说明：现有设备为 16GB 显存。ORION 完整推理（含 LLaMA-7B VLM）需 FP16 约 18GB，超出限制；但 BEV 不确定性热力图仅需 EVAViT + QT-Former（约 0.73GB），可在本地完整运行。FiLM 重训若使用 INT8 量化约需 13GB，本地可尝试但存在显存紧张风险，建议在服务器上完成。

6.2 存储资源

表 10: 数据资产存储需求

数据	大小	说明
Bench2Drive 数据集	407 GB	原始数据（已就位）
ORION 模型 + LLM 权重	~50 GB	已就位
预提取 patch tokens	235 GB	已就位
Checkpoints + 结果	~1 GB	持续增长
总计	~693 GB	

6.3 软件环境

- Python 3.11.5, PyTorch 2.1.0, CUDA 11.8
- 使用 `uv` 管理虚拟环境 (`.venv/`)
- ORION 原始依赖 + UQ 扩展依赖 (`requirements_uq.txt`)

7 可行性分析

7.1 技术可行性

技术可行性评估：

1. **UQ 估计已验证**：AUROC=0.954 远超 0.7 目标，Spearman $\rho=0.97$ ，天气排序完全正确。UQ estimation 部分技术路线已经走通。
2. **FiLM 注入机制已验证**：恶劣天气碰撞率降低 23%，证明 FiLM 调制确实能改变模型行为。
3. **Score-Gated 方案改动量小**：仅需修改 ~6 行代码 + 重训 FiLM，技术风险低。
4. **消融实验框架已就绪**：配置文件、训练/评估脚本、可视化工具全部就位。

7.2 风险评估

表 11: 风险评估矩阵

风险	概率	影响	缓解措施
Score-Gated FiLM 未能完全解决 Normal 退化	低	高	理论上 score=0 时恒等, 若仍退化则检查 UQEstimator 对 Normal 帧的误判率
BEV 热力图过于平滑 (QT-Former attention 非局域性)	中	中	优先用最后一层 attention; 若仍平滑则改用 gradient-weighted attention (类 Grad-CAM)
D 组与 F 组无显著差异 (空间性贡献存疑)	中	高	转向 per-BEV-query Spatial FiLM 方案; BEV Cost 作为辅助验证
碰撞改善幅度不够显著	中	高	扩大评估场景数 (100+); 补充 Bench2Drive 高危场景子集分析
消融某组件贡献不显著	中	低	如实报告, 可作为“轻量简化版”的卖点

7.3 创新点与论文贡献

- 发现:** 端到端 VLM 驾驶在恶劣天气下碰撞率放大 161 $\times$, 但开环 L2 指标无法反映; L2 精度与安全性是两个正交维度
- 方法 (第一层):** 轻量 UQ 估计器 + Score-Gated FiLM, 通过感知不确定性对 QT-Former 和 VAE 实施条件调制, 零主干微调, 参数增量仅 4.45M
- 方法 (第二层, 新贡献):** 将 per-patch 图像质量通过 QT-Former cross-attention 传播为 BEV 不确定性热力图, 直接约束轨迹模式选择, 首次实现感知可靠性的空间感知规划
- 定位:** 即插即用设计, 适用于任意冻结的端到端驾驶模型, 无需重训骨干网络
- 分析:** 系统消融实验 (UQ 组件 / FiLM 层级 / 全局 vs 空间不确定性) 揭示各模块贡献

8 时间规划

表 12: 后续工作时间规划（括号内为所需计算资源）

时间	任务	交付物
第 1 周	Phase 0: 信号验证 + Score-Gated 代码实现（本地）	验证图 + 代码
第 1-2 周	BEV 不确定性热力图计算与可视化（本地）	热力图对比图（论文图）
第 2 周	λ 训练与 mode cost 验证（本地）	λ checkpoint
第 2-3 周	Score-Gated FiLM 重训 + 开环评估（A100）	更新版表 5
第 3 周	UQ 消融（4 组）+ FiLM 层级消融（A100）	消融对比表
第 3-4 周	完整 6 组闭环评估（A100 + CARLA, 100 场景）	主要实验表
第 4-5 周	论文 Method + Experiments 初稿	草稿
第 5-6 周	Introduction + Related Work + 图表	完整初稿
第 6-7 周	审阅修改 + 定稿	可投稿版本

9 总结

UQ-ORION 项目第一阶段已完成核心验证：UQEstimator 在恶劣天气检测上达到 AUROC=0.954，FiLM 碰撞感知训练在恶劣天气场景降低了 23% 的碰撞率。当前主要问题是 FiLM 对正常场景的非预期干扰（ADE +116%），根因已明确为 FiLM 调制的全局性与 LayerNorm 范数崩塌。

第二阶段以此为切入点，提出 BEV 不确定性热力图方案，将感知可靠性空间化，直接指导轨迹模式选择。该方案的核心计算链路（EVAViT + QT-Former + 图像统计量）不依赖 LLM，可在现有 16GB 本地设备上完整运行，具备近期快速推进的条件。需申请 A100 资源的部分（FiLM 重训、大规模闭环评估）预计总 GPU 时间约 103 小时。预计 6-7 周内可完成论文初稿。